

Jaki to PTAK?

Stworzenie modelu do rozpoznawania ptaków na terenie Ameryki Północnej



zespół projektowy "itdepends"



Elżbieta Chruściel



Katarzyna Donaj



Tomasz Mazur



Bartłomiej Brzostek

Cel:

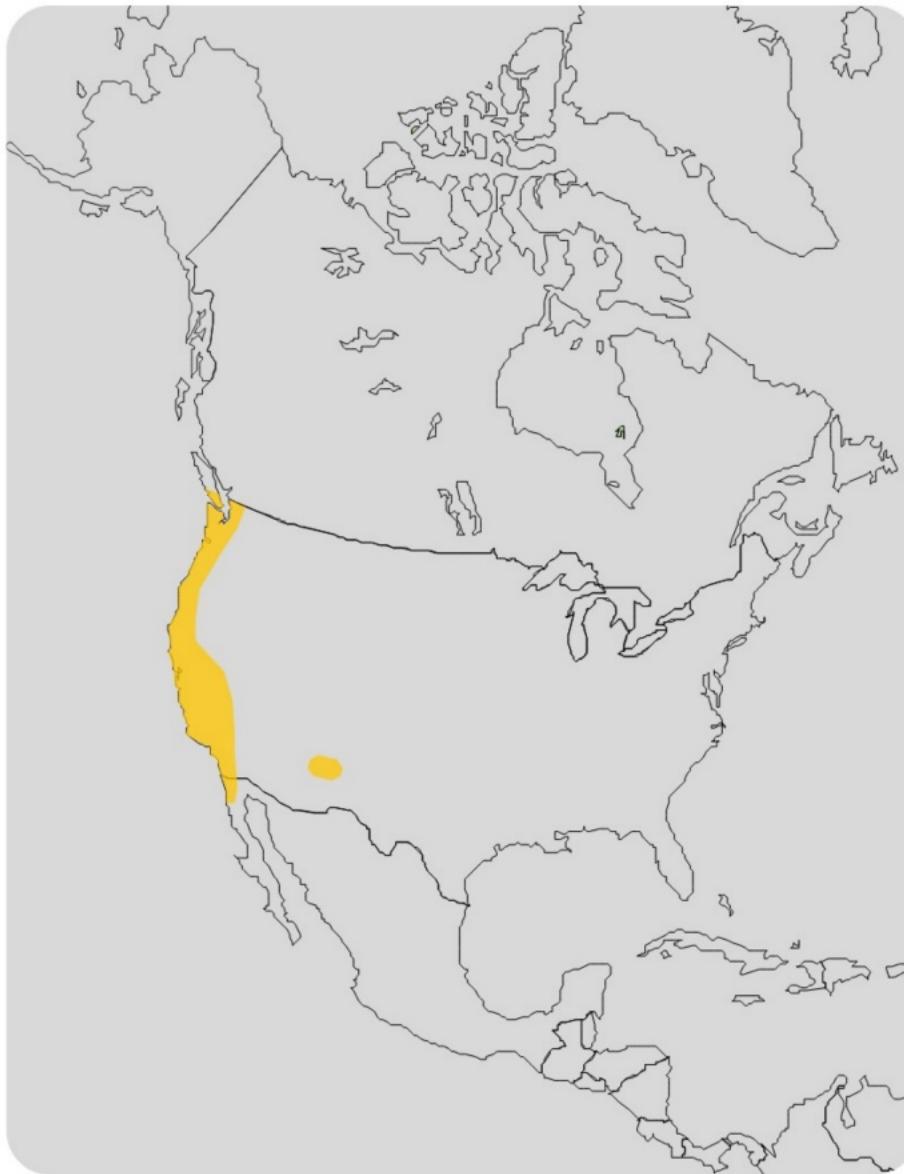
**Stworzenie modelu do rozpoznawania
zagrożonych gatunków zagrożonych ptaków
na terenie Ameryki Północnej**

Stakeholder:

- Agencja Ochrony Ptaków w NA, która chce dokonać szybkiej klasyfikacji ptaków zagrożonych na podstawie zdjęć**
- Pasjonaci ornitolodzy z całego świata**

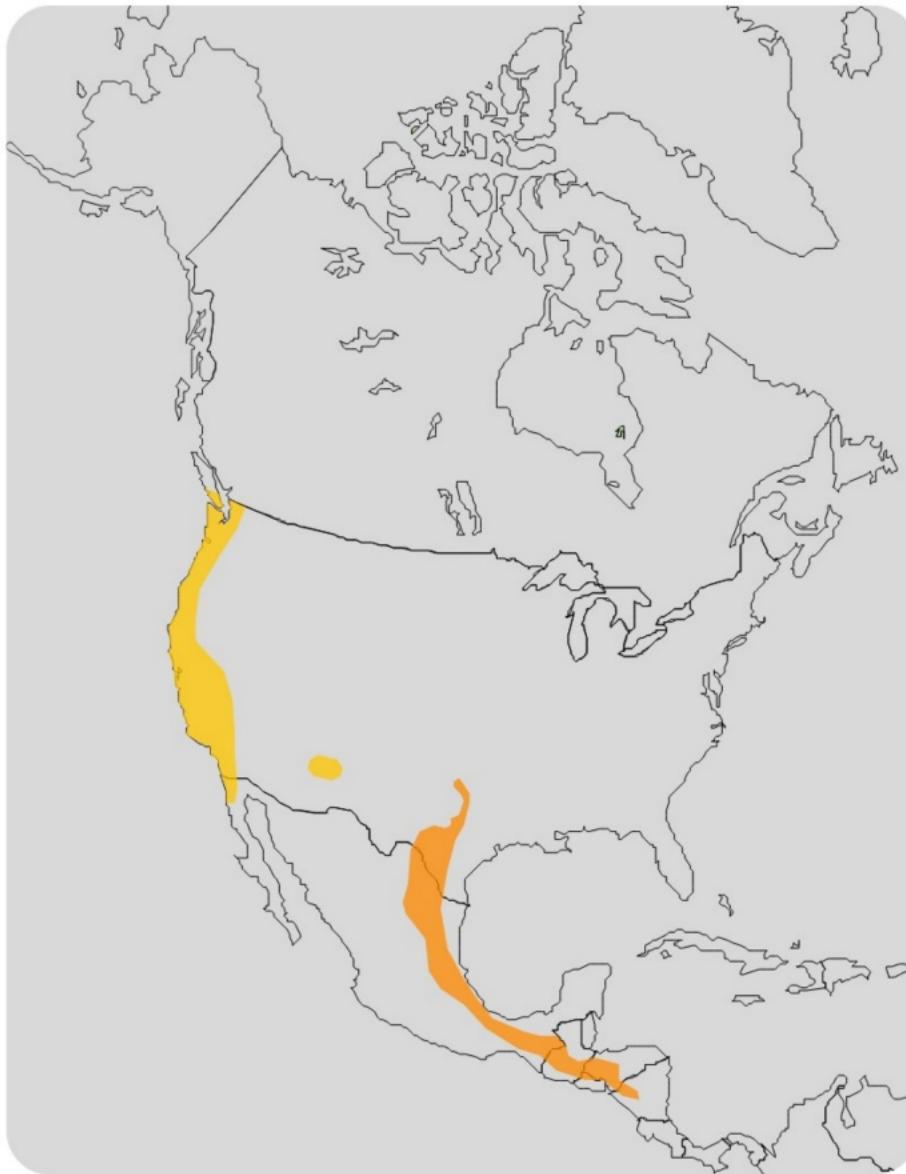


Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski

Obszary występowania wybranych do projektu gatunków ptaków

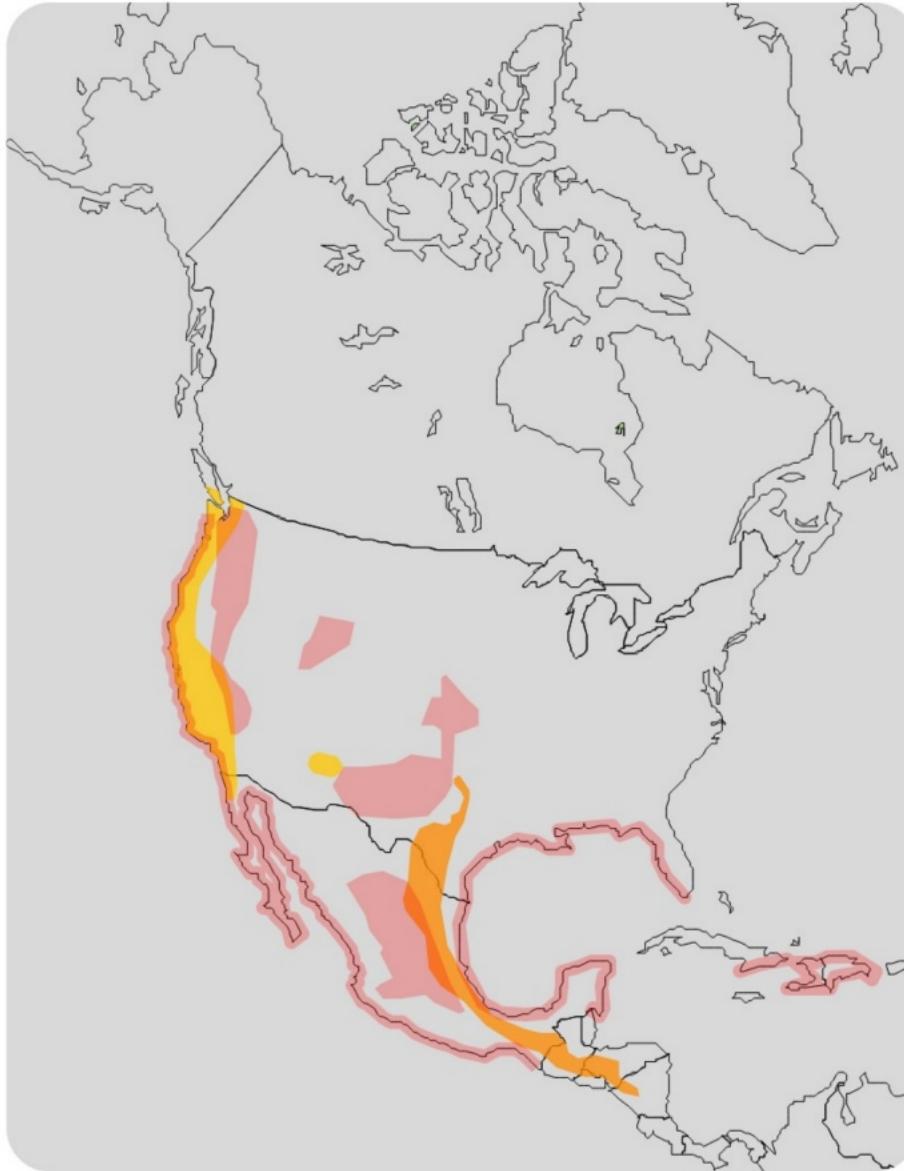


kondor kalifornijski



lasówka żółtolica

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski

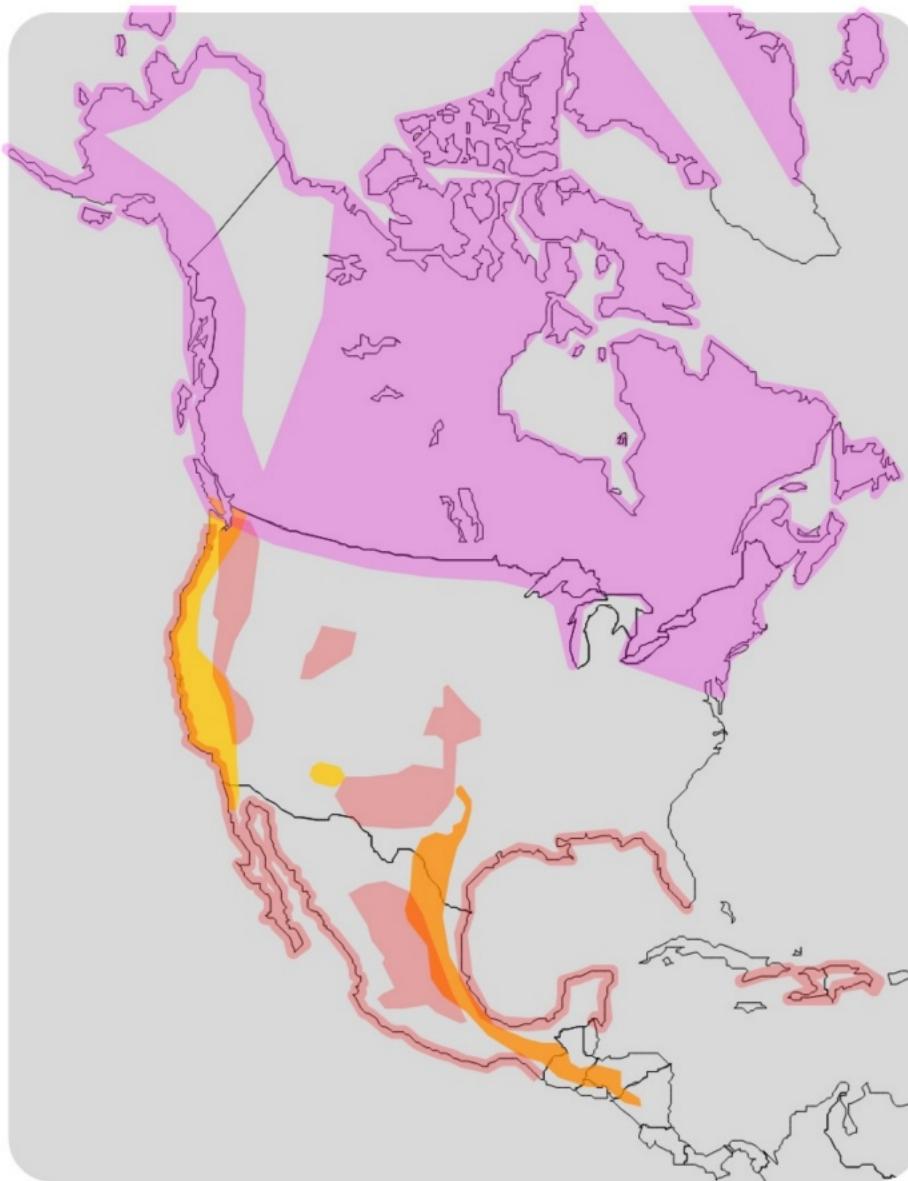


lasówka żółtolica



sieweczka jasna

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski



lasówka żółtolica

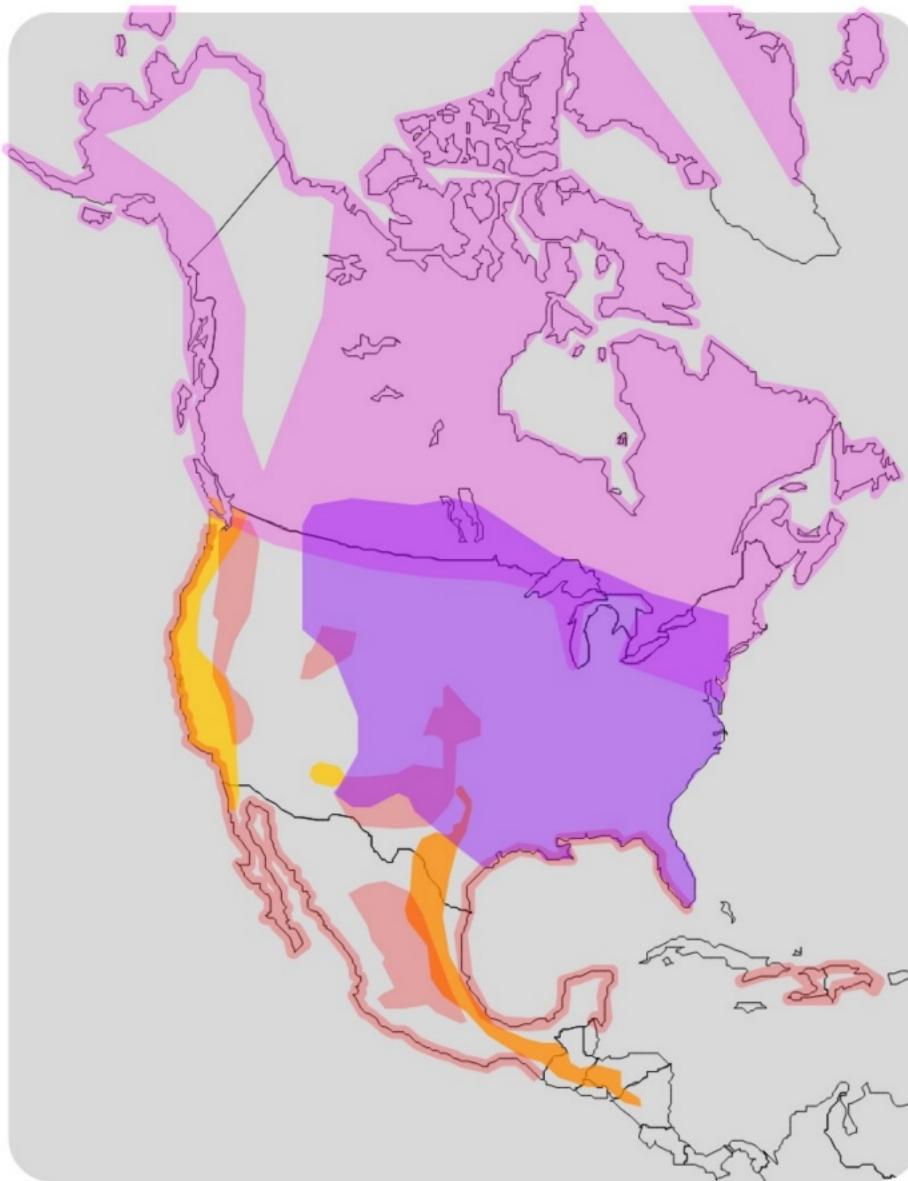


sieweczka jasna



sowa śnieżna

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski



lasówka żółtolica



sieweczka jasna

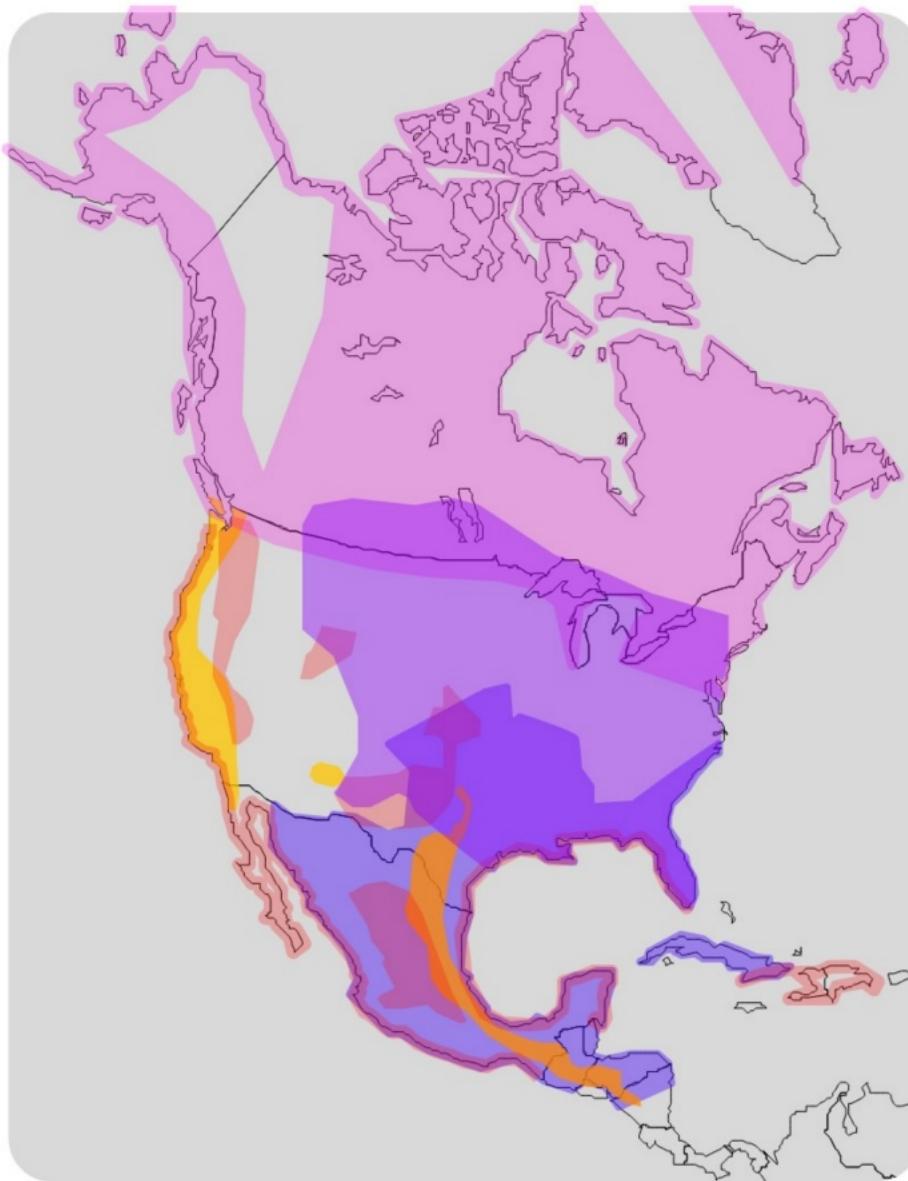


sowa śnieżna



dziecioł krasnogłowy

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski



lasówka żółtolica



sieweczka jasna



sowa śnieżna

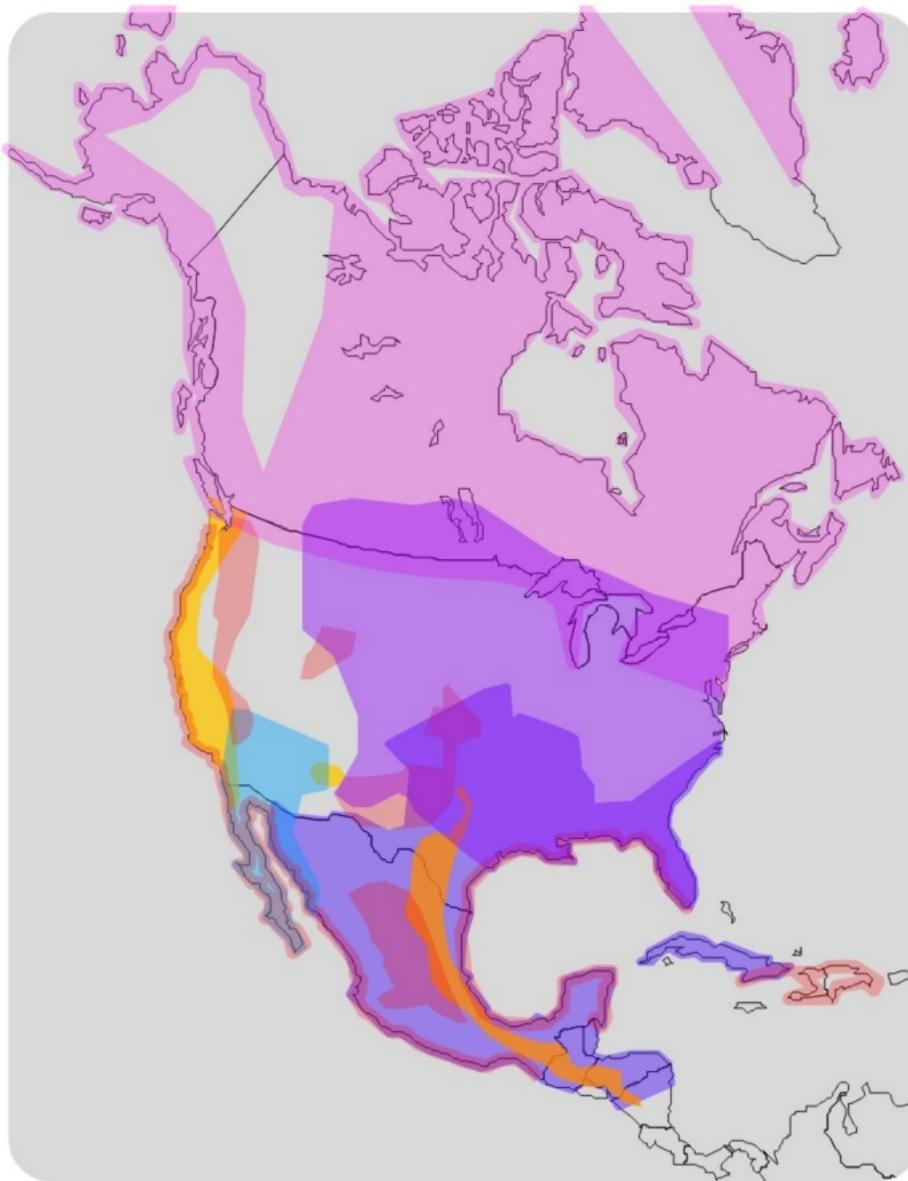


dzięcioł krasnogłowy



łuszczyk wielobarwny

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski



lasówka żółtolica



sieweczka jasna



sowa śnieżna



dzieciol krasnogłowy

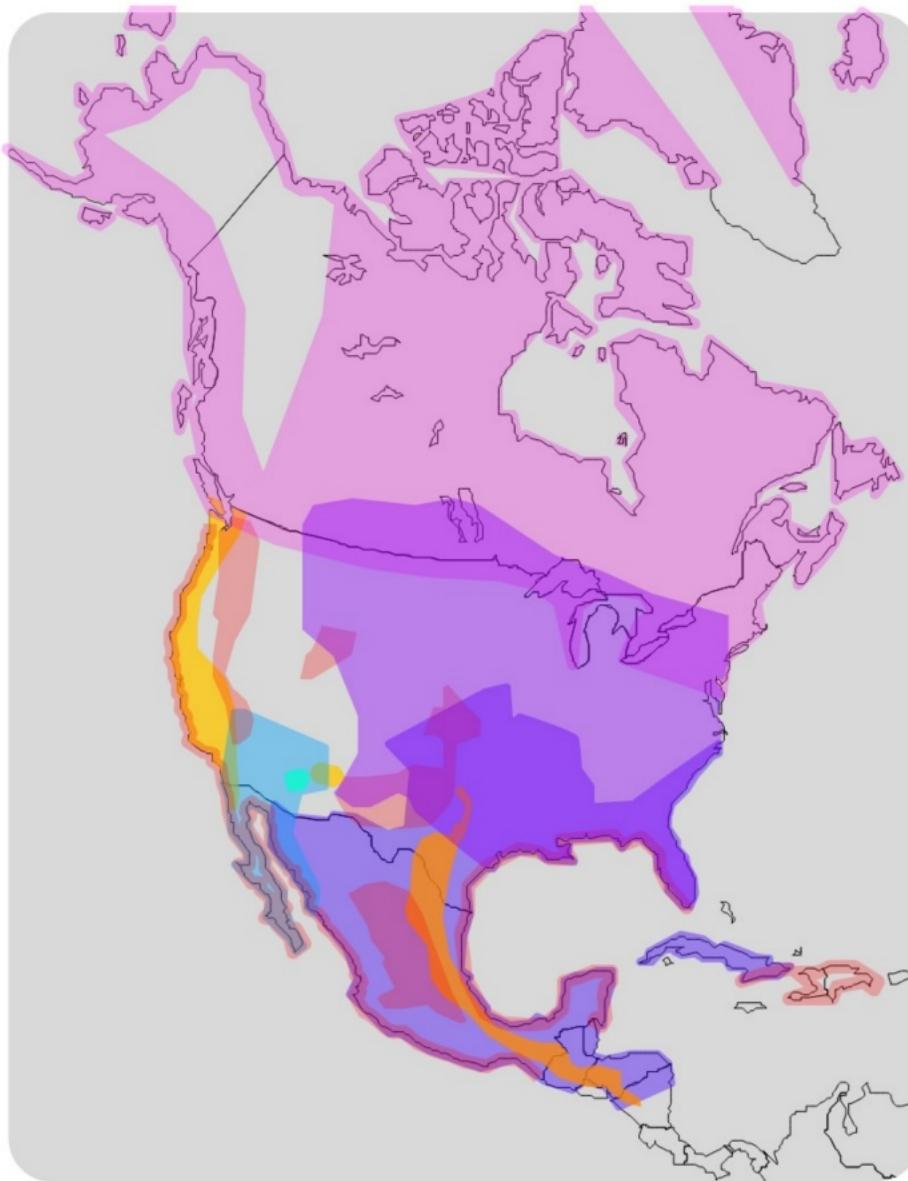


łuszczyk wielobarwny



dzieciol różowoszyi

Obszary występowania wybranych do projektu gatunków ptaków



kondor kalifornijski



lasówka żółtolica



sieweczka jasna



sowa śnieżna



dzięcioł krasnogłowy



łuszczyk wielobarwny

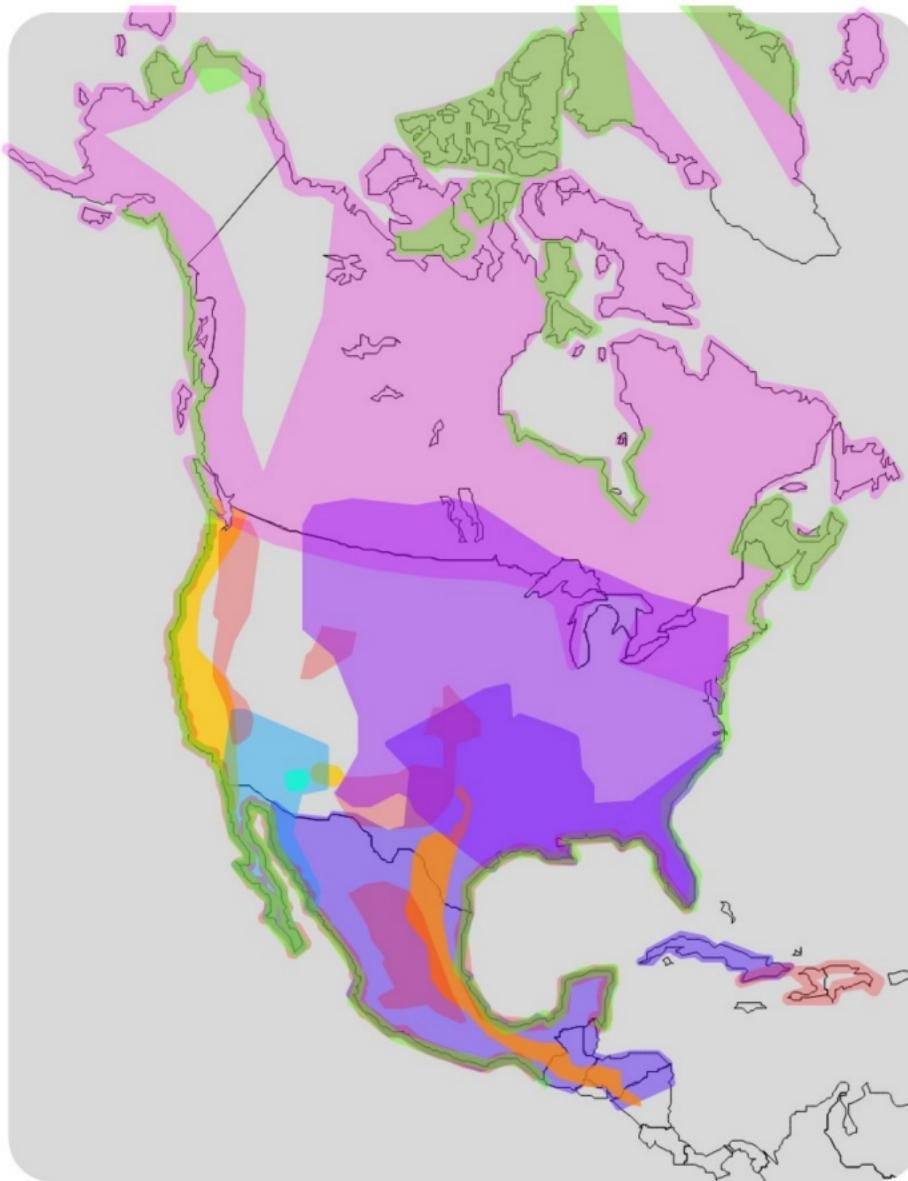


dzięcioł różowoszyi



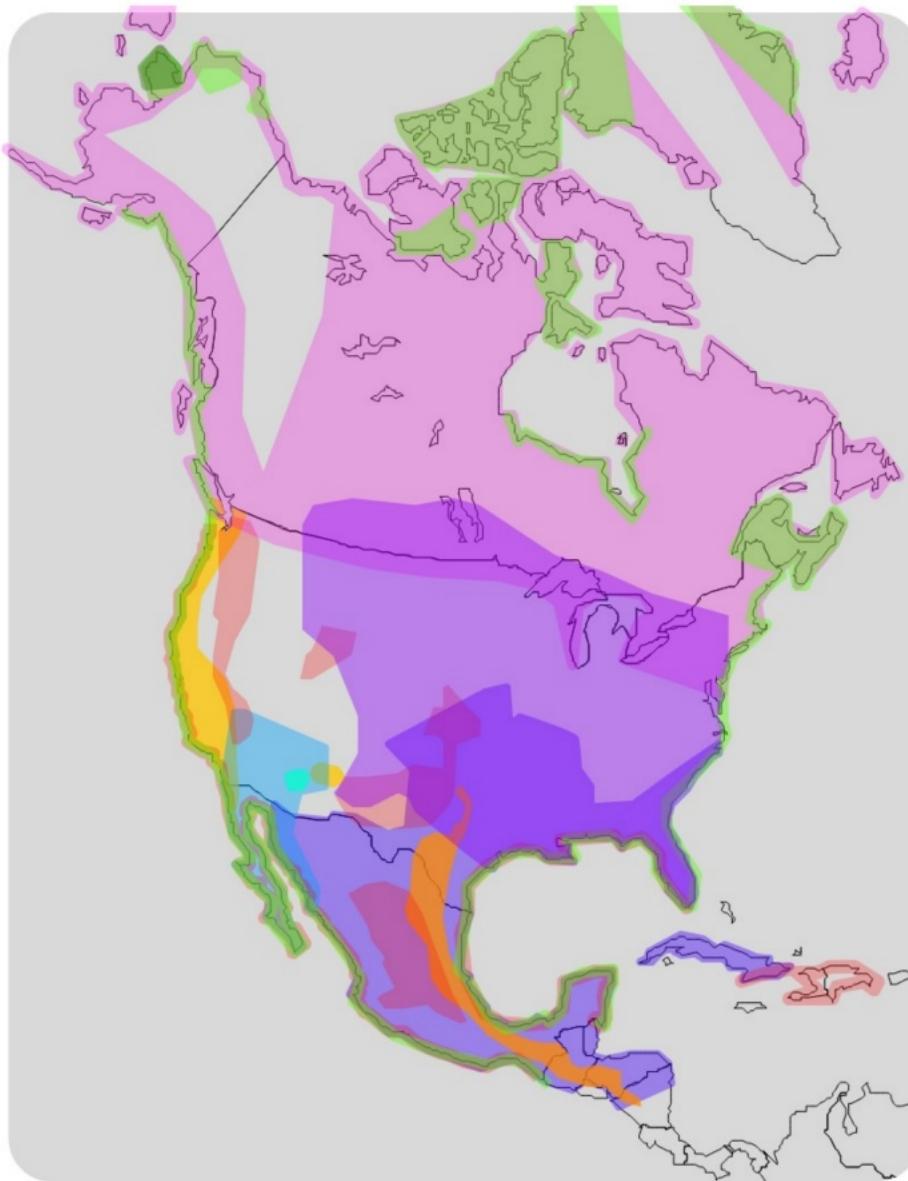
przepiór wirgiński

Obszary występowania wybranych do projektu gatunków ptaków



- | | |
|--|----------------------|
| | kondor kalifornijski |
| | lasówka żółtolica |
| | sieweczka jasna |
| | sowa śnieżna |
| | dzieciol krasnogłowy |
| | luszczyk wielobarwny |
| | dzieciol różowoszyi |
| | przepiór wirgiński |
| | biegus rdzawy |

Obszary występowania wybranych do projektu gatunków ptaków



- | | |
|--|----------------------|
| | kondor kalifornijski |
| | lasówka żółtolica |
| | sieweczka jasna |
| | sowa śnieżna |
| | dzieciol krasnogłowy |
| | luszczyk wielobarwny |
| | dzieciol różowoszyi |
| | przepiór wirgiński |
| | biegus rdzawy |
| | biegus łyżkodzioby |

Ptasie ciekawostki:

	LC	Least Concern
	NT	Near Threatened
	VU	Vulnerable
	EN	Endangered
	CR	Critically Endangered
	EW	Extinct in the Wild
	EX	Extinct
	DD	Data Deficient
	NE	Not Evaluated

Dzięcioł krasnogłowy

- Zaciekły obrońca swojego terytorium: rozbija jaja i niszczy gniazda innych ptaków.
- Był symbolem wojennym Indian Cherokee.



Dzięcioł różowoszy

Zamieszkuje tereny pustynne, gdzie poluje na mrówki znajdujące się pod ziemią.



Łuszczek wielobarwny



Ze względu na swoje piękno są nielegalnie odławiane na handel, co stanowi dla nich jedno z największych zagrożeń.

Biegus rdzawy

Pokonuje ok. 15 tys. km podczas wędrówki z krańca Ameryki Południowej do koła podbiegunowego.



Sieweczka jasna

Samica łączy się z wieloma samcami w sezonie lęgowym: Po wykluciu piskląt szuka nowego partnera, a opiekę nad młodymi przejmują samce.



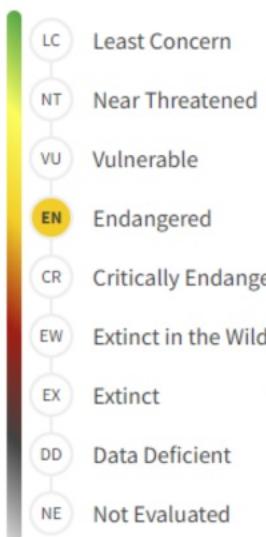
Slappy Sackson Photography

Ptasie ciekawostki:

Sowa śnieżna

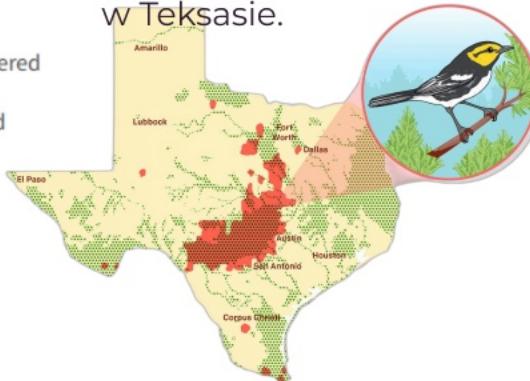


- W przeciwieństwie do większości sów, jest aktywna w dzień.
- Poluje całą dobę podczas lata polarnego.



Lasówka żółtolica

Jest gatunkiem endemicznym: Cała jego populacja gniazduje wyłącznie w Teksasie.



Przepiór wirgiński

- Jego liczebność tak gwałtownie spadła, że był uznany za wymarłego.
- Obecnie prowadzi się programy reintrodukcji, w których samce spokrewnionego z nim gatunku uczą pisklęta jak przetrwać na wolności.



Kondor kalifornijski

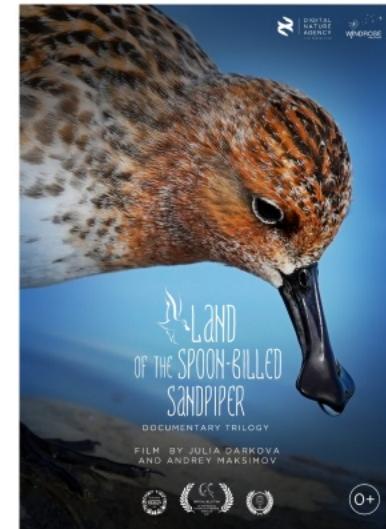


- Niemal całkowicie wytępiony przez człowieka.
- W 1987 roku na wolności pozostało 27 osobników.
- Pozostałe przy życiu kondory złapano i od tamtej pory prowadzony jest program ratowania gatunku.
- Populację udało się zwiększyć do ok. 560 osobników.

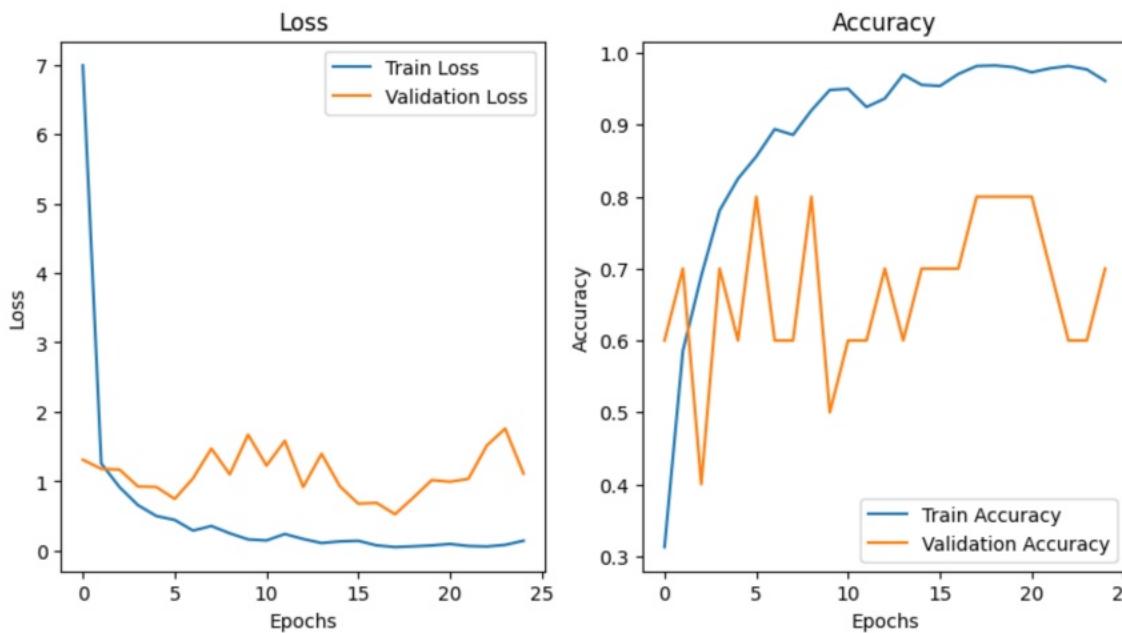


Biegus łyżkodzioby

- W ciągu 50 lat populacja spadła o 90% do zaledwie ok. 150 par.
- Uważa się, że gatunek ten rozmnaża się tylko w Rosji, ale pojedyncze obserwacje sugerują istnienie małych populacji na Alasce.



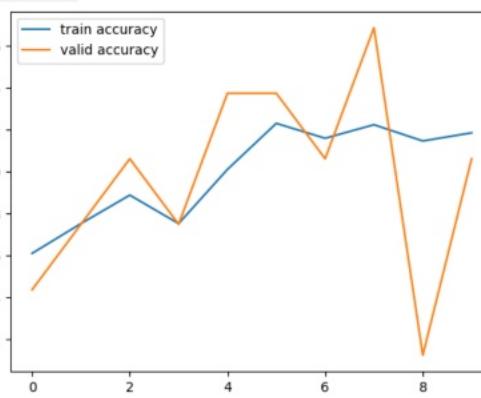
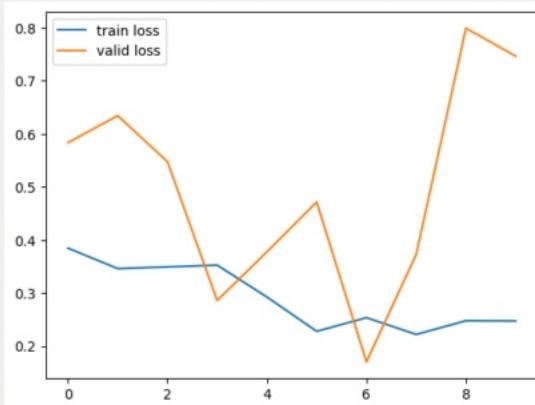
Porównanie wyników modelu sieci neuronowej w zależności od hiperparametrów



convNum=[16,32,64,128],
hNum=[128],
hAct="relu",
outNum=10,
loss=tf.keras.losses.CategoricalCrossentropy(),
dropout_rate=0.5
Ilość epok: 25

Validation accuracy: 80%
Test accuracy: 68%

Porównanie wyników modelu sieci neuronowej w zależności od hiperparametrów



convNum=[32,64,128],
hNum=[128],
hAct="relu",
outNum=10,
loss=tf.keras.losses.CategoricalCrossentropy(),
dropout_rate=0.5
Ilość epok: 10

valid accuracy: 94%

zautomatyzowane porównanie wyników modelu sieci



```
C:\Users\tom\PycharmProjects\pythonProject\venv\Scripts\python.exe C:\Users\tom\PycharmProjects\pythonProject\test.py
import os,
import pandas as pd,
import numpy as np,
from pathlib import Path,
from sklea
```





```
(SELECT * FROM model_results_5 ORDER BY accuracy DESC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_5 ORDER BY loss ASC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_10 ORDER BY accuracy DESC LIMIT
UNION ALL
(SELECT * FROM model_results_10 ORDER BY loss ASC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_15 ORDER BY accuracy DESC LIMIT
UNION ALL
(SELECT * FROM model_results_15 ORDER BY loss ASC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_20 ORDER BY accuracy DESC LIMIT
UNION ALL
(SELECT * FROM model_results_20 ORDER BY loss ASC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_25 ORDER BY accuracy DESC LIMIT
UNION ALL
(SELECT * FROM model_results_25 ORDER BY loss ASC LIMIT 1)
UNION ALL
(SELECT * FROM model_results_30 ORDER BY accuracy DESC LIMIT
UNION ALL
(SELECT * FROM model_results_30 ORDER BY loss ASC LIMIT 1);
```

	params	loss	accuracy
1	{'conv_filters': 16, 'conv_layers': 2, 'dense_units': 128, 'dropout_rate': 0.3}	0.5366870760917664	0.8799999952316284
2	{'conv_filters': 64, 'conv_layers': 2, 'dense_units': 128, 'dropout_rate': 0.3}	0.46526142954826355	0.8600000143051147
3	{'conv_filters': 64, 'conv_layers': 3, 'dense_units': 128, 'dropout_rate': 0.3}	0.3829604387283325	0.8799999952316284
4	{'conv_filters': 64, 'conv_layers': 3, 'dense_units': 128, 'dropout_rate': 0.3}	0.3829604387283325	0.8799999952316284
5	{'conv_filters': 32, 'conv_layers': 2, 'dense_units': 128, 'dropout_rate': 0.5}	0.5712341666221619	0.9200000166893005
6	{'conv_filters': 128, 'conv_layers': 2, 'dense_units': 64, 'dropout_rate': 0.5}	0.39608603715896606	0.8600000143051147
7	{'conv_filters': 64, 'conv_layers': 3, 'dense_units': 128, 'dropout_rate': 0.3}	0.71775221824646	0.9200000166893005
8	{'conv_filters': 32, 'conv_layers': 3, 'dense_units': 128, 'dropout_rate': 0.5}	0.3846723139286041	0.8600000143051147
9	{'conv_filters': 128, 'conv_layers': 2, 'dense_units': 128, 'dropout_rate': 0.5}	0.5322757959365845	0.9399999976158142
10	{'conv_filters': 16, 'conv_layers': 2, 'dense_units': 64, 'dropout_rate': 0.3}	0.3840716481208801	0.8399999737739563

Model wykorzystujący sieć MobileNetV2 jest najbardziej skuteczny

MobileNetV2

prosty i wydajny model
(ok. 3,5 mln parametrów)

ResNet50

zapewnia równowagę między stopniem skomplikowania a wydajnością
(ok. 25 mln parametrów)

VGG16

bardzo duży i złożony model
(ok. 135 mln parametrów)



Zmodyfikowane warstwy wierzchnie:

- 1) warstwa GlobalAvaragePooling2D
- 2) warstwa gęsta (1024 neuronów, aktywacja relu)
- 3) warstwa gęsta (10 neuronów, aktywacja softmax)

Optymalizator: Adam

Callback: EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True)



Wyniki na danych testowych:

MobileNetV2

Accuracy = 0,96
Loss = 0,06

ResNet50

Accuracy = 0,32
Loss = 1,70

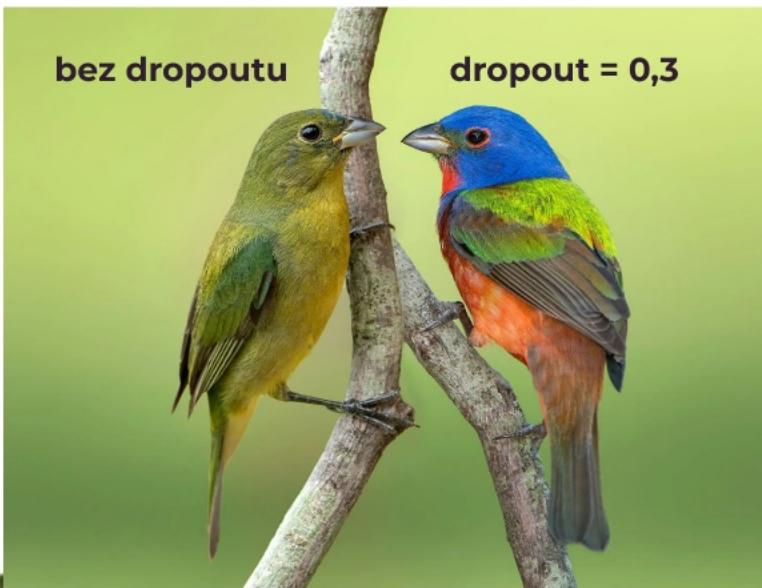
VGG16

Accuracy = 0,92
Loss = 0,34

Dodanie dropoutu zwiększyło skuteczność modelu wykorzystującego MobileNetV2

MobileNetV2

Te same warstwy
wierzchnie, callback
optymalizator Adam

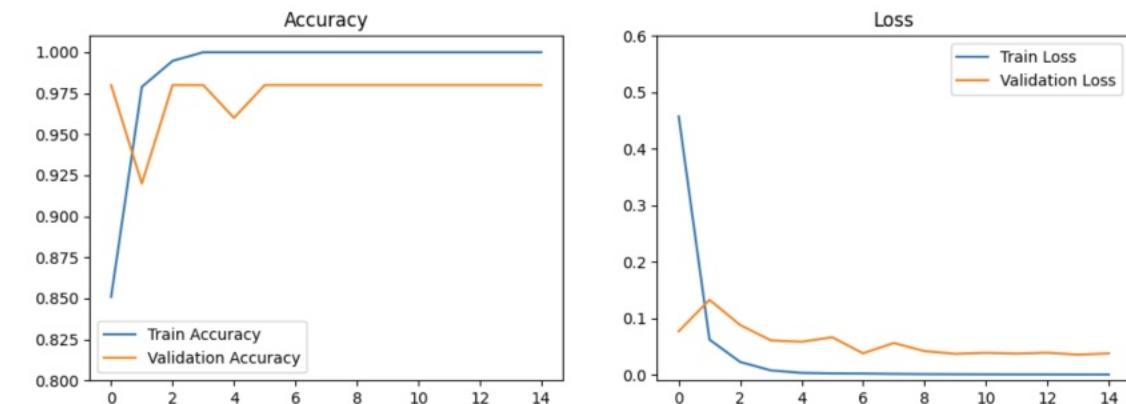


bez dropoutu



Wyniki na danych testowych:

Accuracy = 0,96
Loss = 0,06

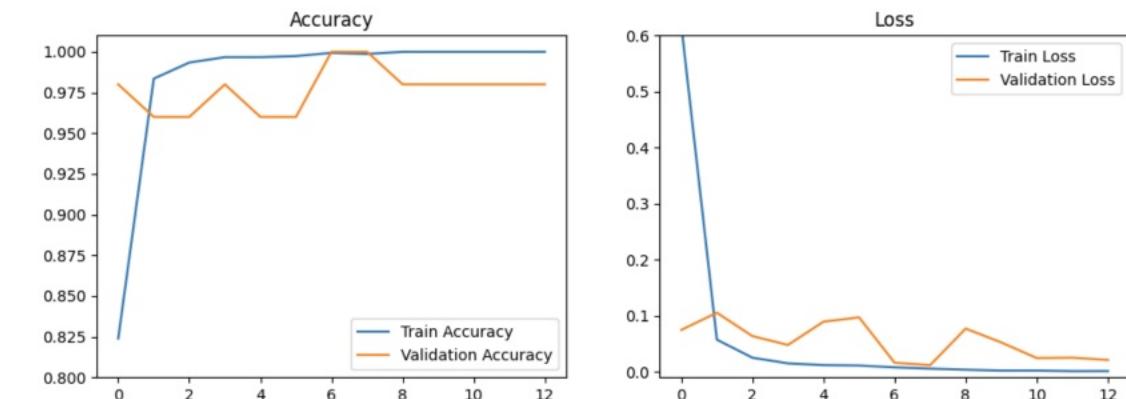


dropout = 0,3



Wyniki na danych testowych:

Accuracy = 0,98
Loss = 0,06



Analogiczny model z optymalizatorem SGD był mniej skuteczny

MobileNetV2

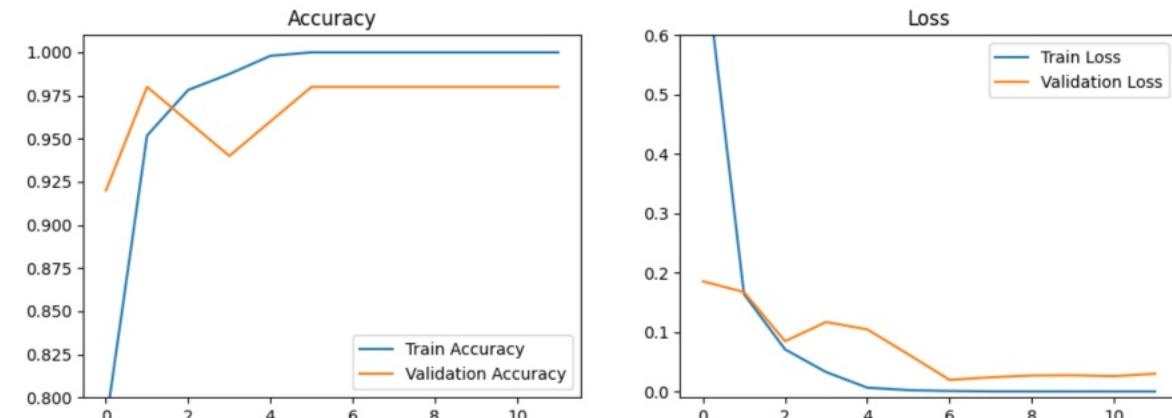
Te same warstwy wierzchnie i callback
optymalizator SGD

learning rate = 0,1

learning_rates = [0.1, 0.01, 0.001, 0.0001]

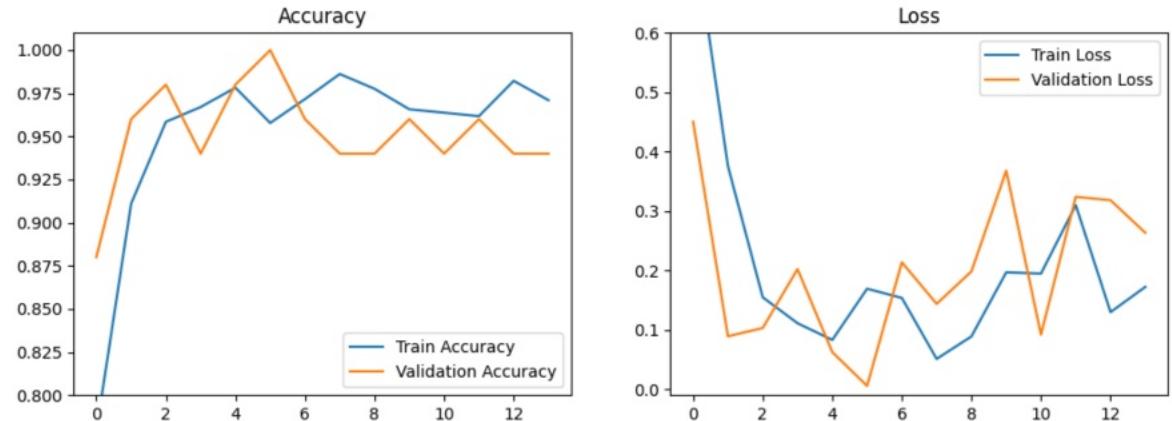
bez dropoutu

Wyniki na danych testowych:
Accuracy = 0,96
Loss = 0,11



dropout = 0,3

Wyniki na danych testowych:
X Accuracy = 0,96
Loss = 0,21



Zwyciązca: zoptymalizowany model wykorzystujący MobileNetV2

MobileNetV2

prosty i wydajny model
(ok. 3,5 mln parametrów)



Zmodyfikowane warstwy wierzchnie:

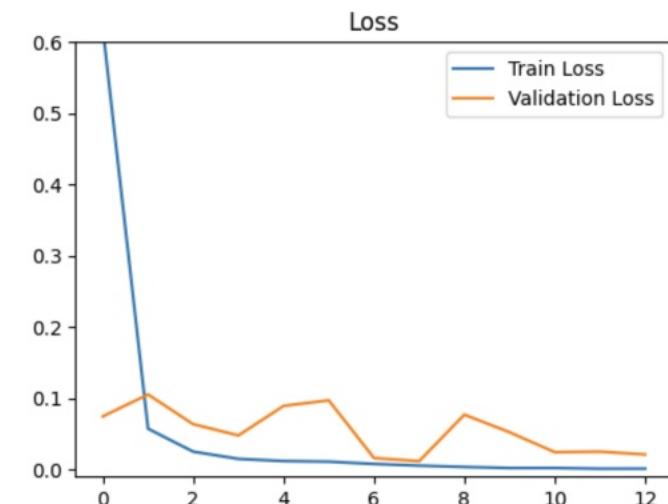
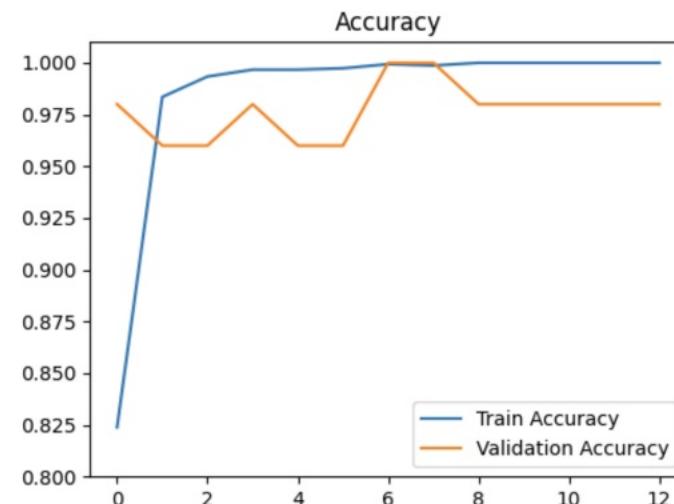
- 1) GlobalAvaragePooling2D
- 2) Dense (1024, activation='relu')
- 3) **Dropout (0.3)**
- 4) Dense (10, activation='softmax')

Optymalizator: Adam

Callback: EarlyStopping(monitor='val_loss',
patience=5, restore_best_weights=True)

Wyniki na danych testowych:

Accuracy = 0,98
Loss = 0,06



Demonstracja działania modelu

Predicted: SPOON BILLED SANDPIPER
True: RED KNOT



Predicted: GILDED FLICKER
True: GILDED FLICKER



Predicted: MASKED BOBWHITE
True: MASKED BOBWHITE



Predicted: SNOWY OWL
True: SNOWY OWL



Predicted: GOLDEN CHEEKED WARBLER
True: GOLDEN CHEEKED WARBLER



Predicted: PAINTED BUNTING
True: PAINTED BUNTING



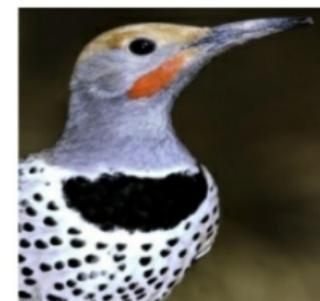
Predicted: SNOWY PLOVER
True: SNOWY PLOVER



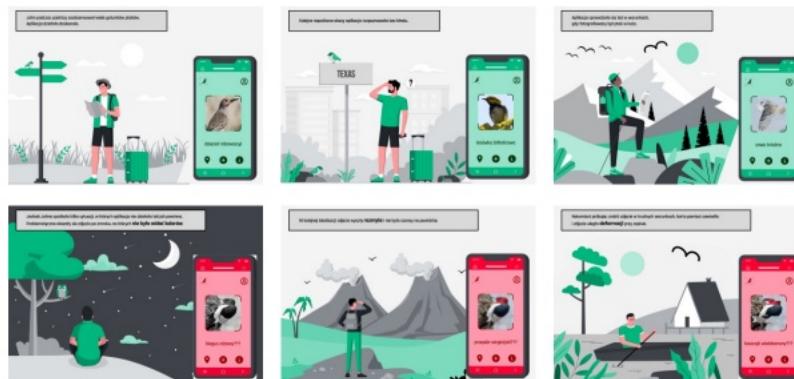
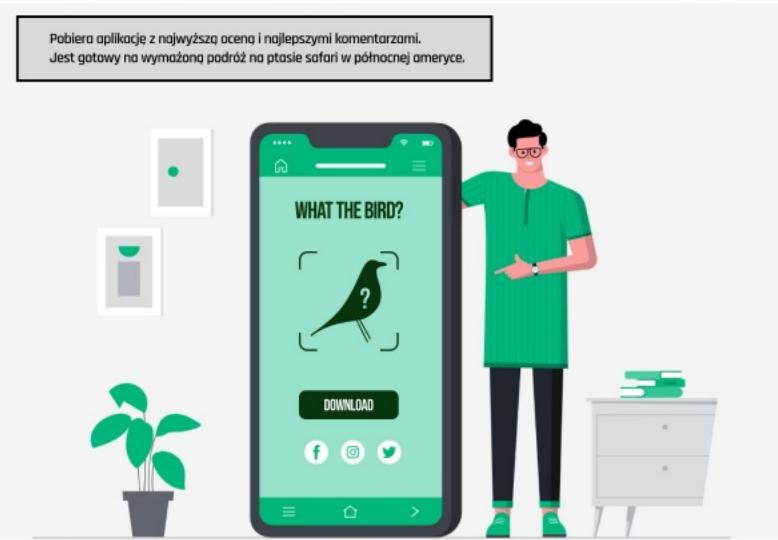
Predicted: RED HEADED WOODPECKER
True: RED HEADED WOODPECKER



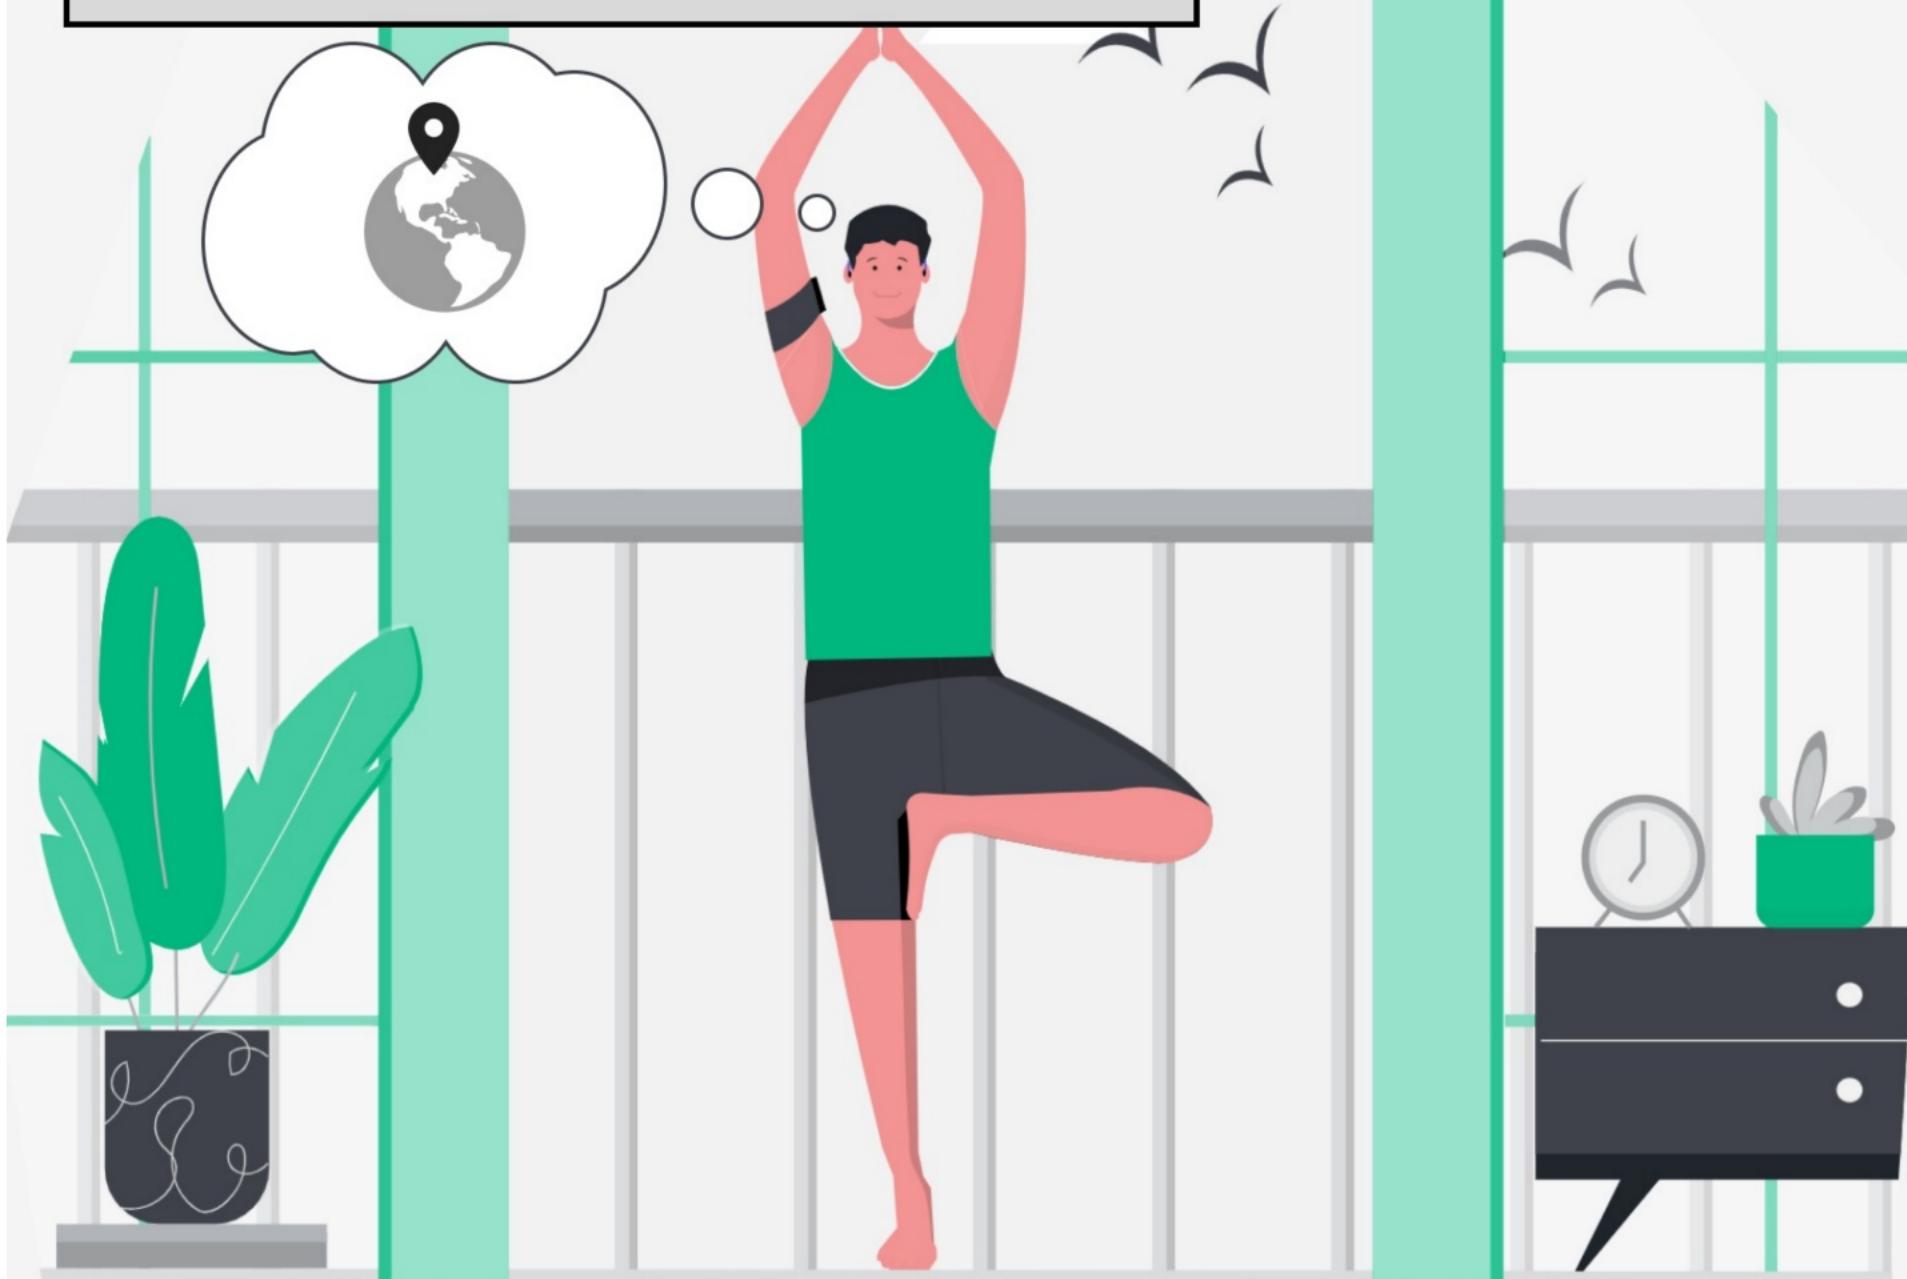
Predicted: GILDED FLICKER
True: GILDED FLICKER



aplikacja do rozpoznawania ptaków



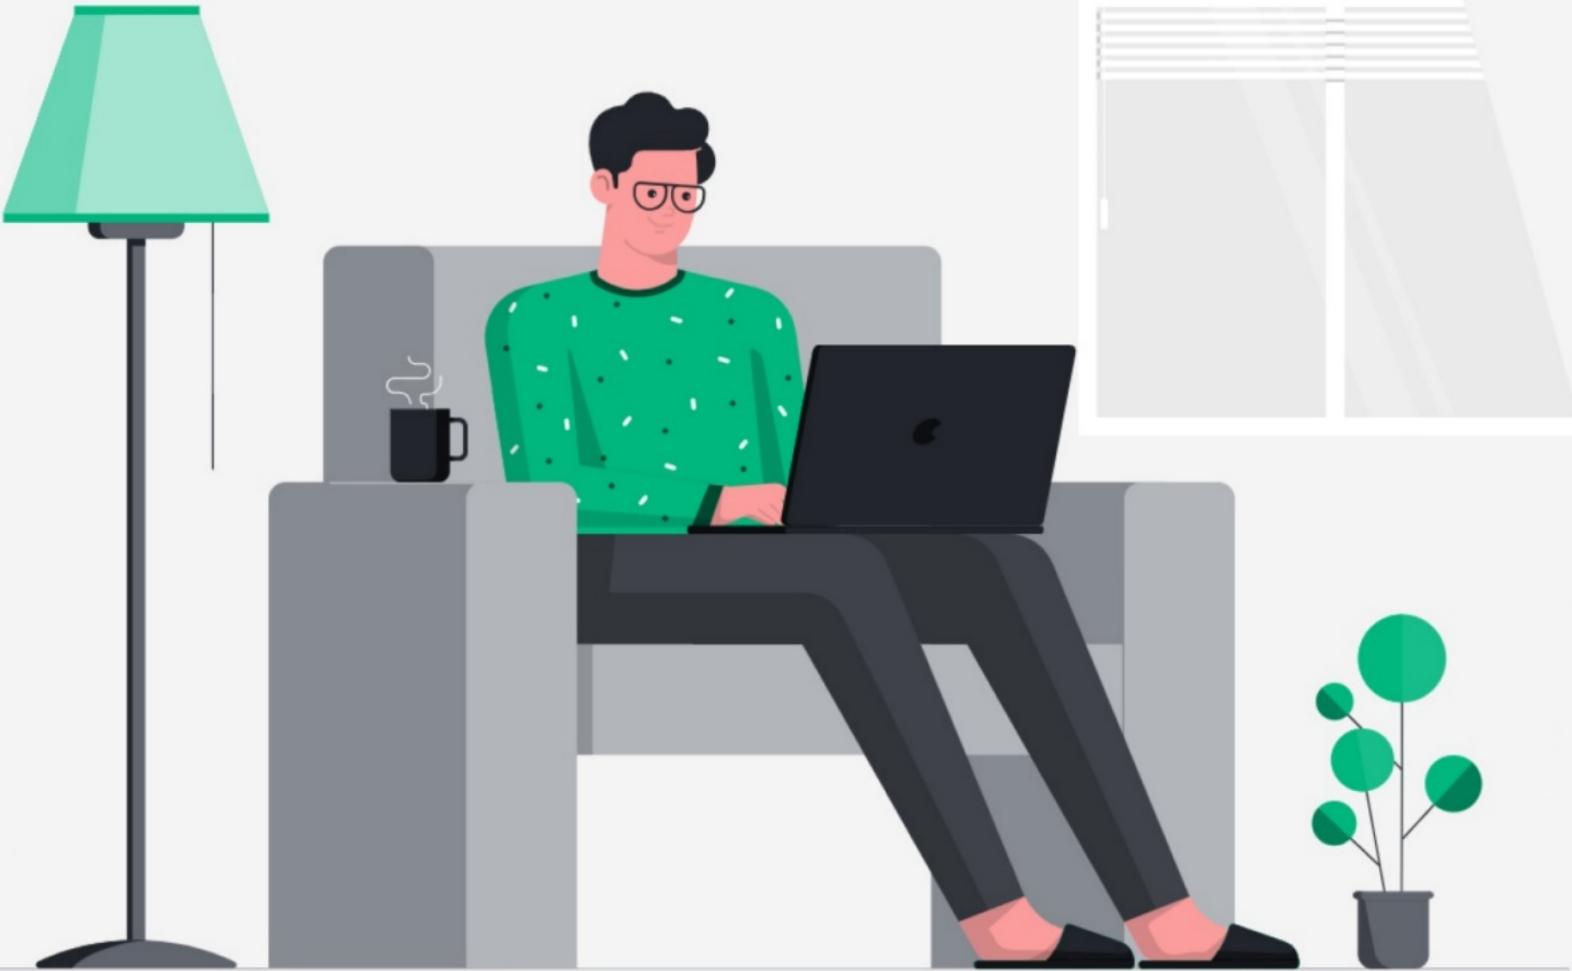
To jest John. John chce pojechać do północnej ameryki na ptasie safari.



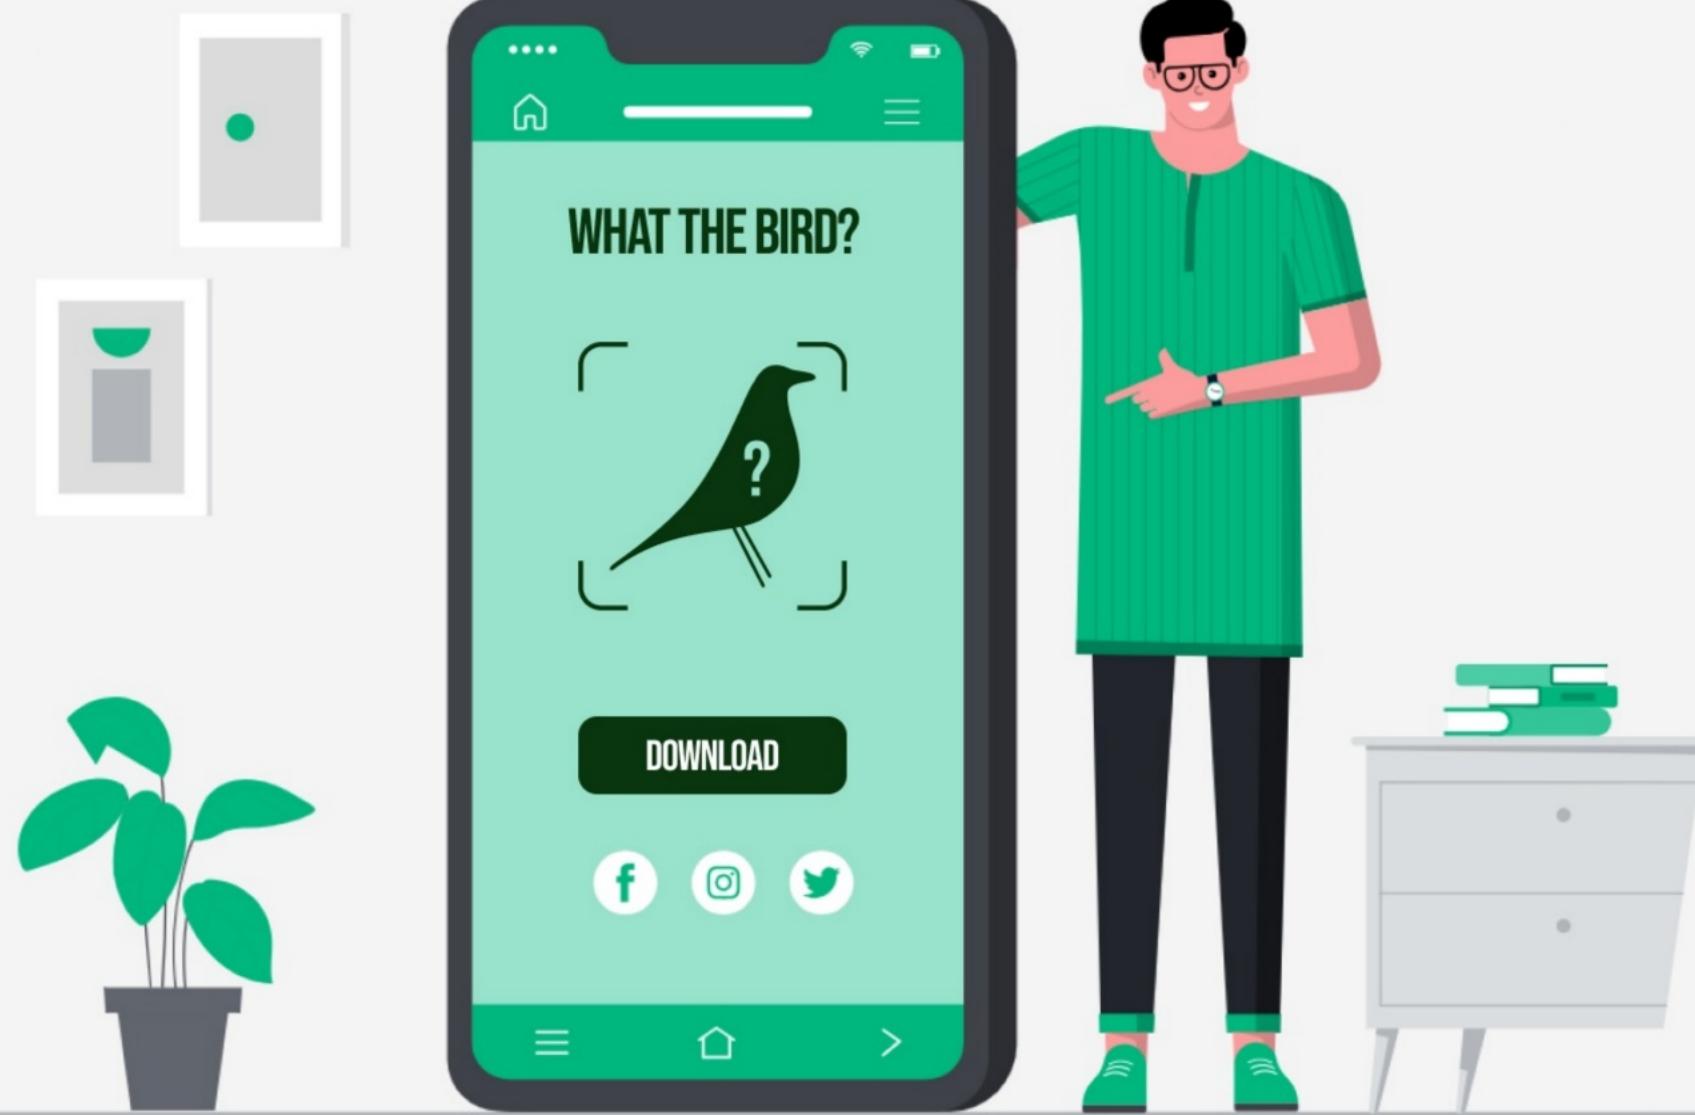
Wyszukaj

Wyszukuje aplikację, która pomoże mu rozpoznać gatunki ptaków.

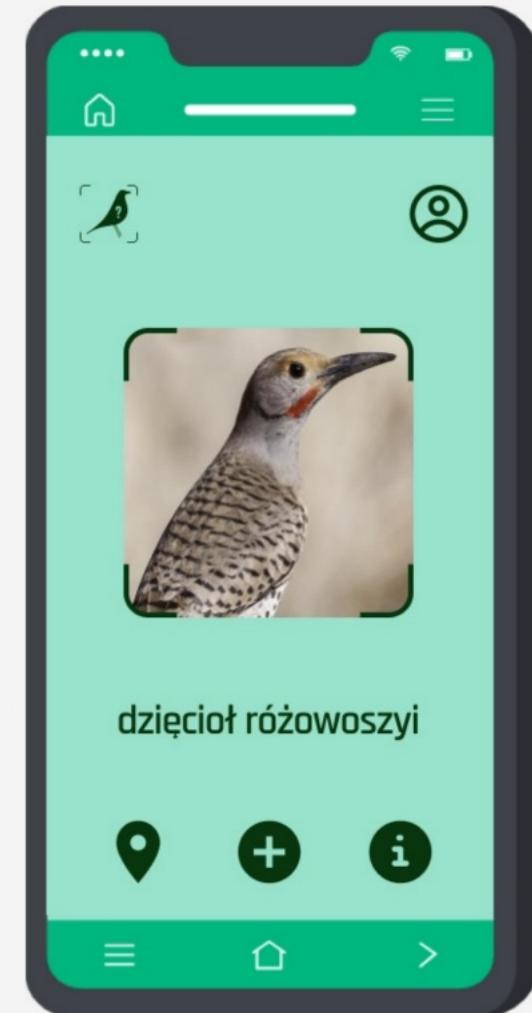
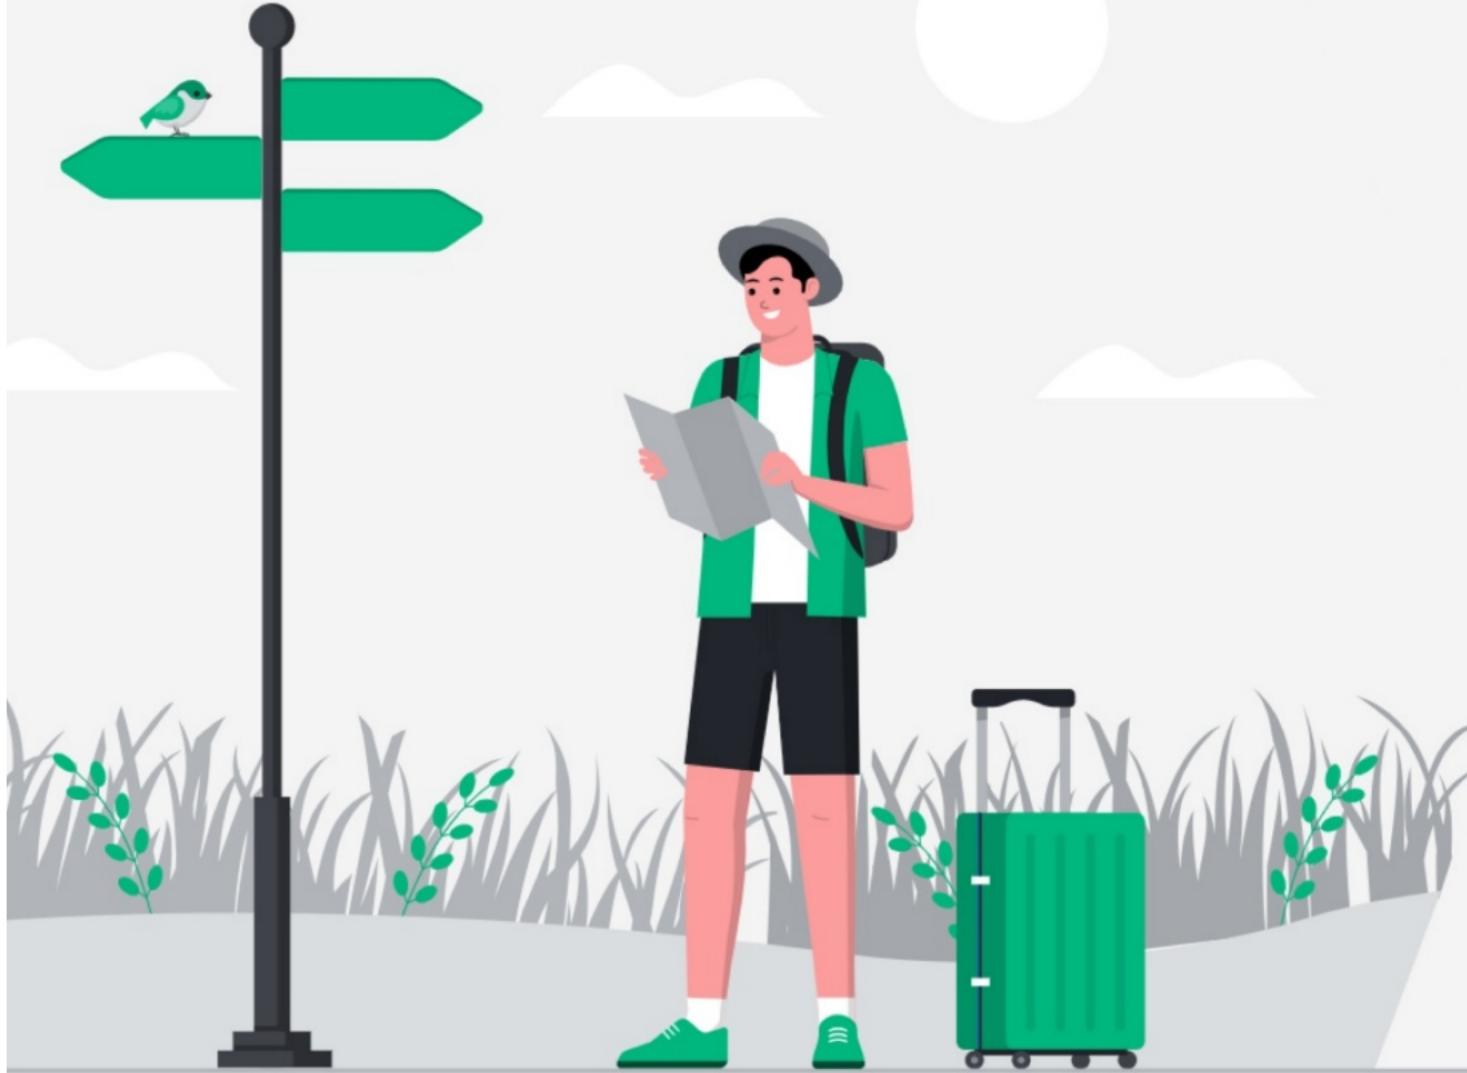
ptasie safari usa najlepsza aplikacja



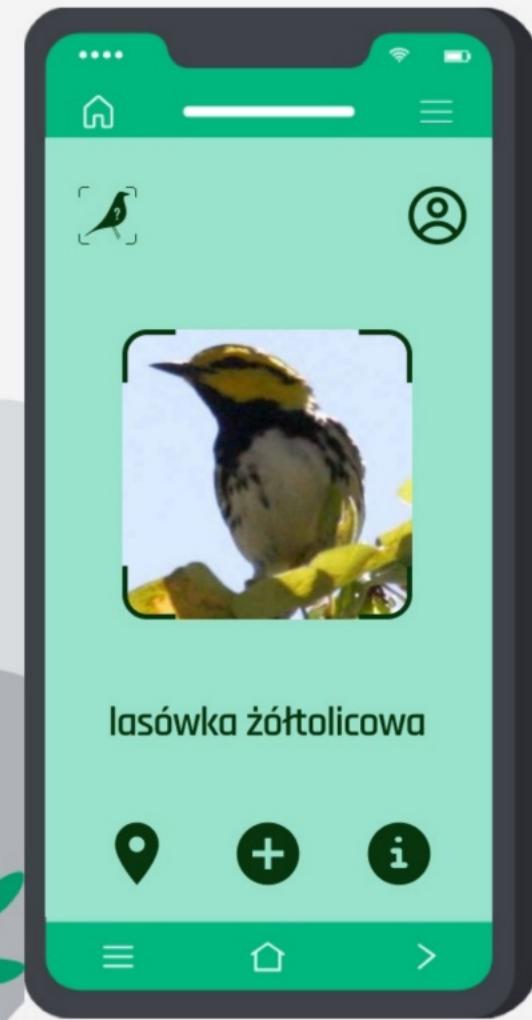
Pobiera aplikację z najwyższą oceną i najlepszymi komentarzami.
Jest gotowy na wymażoną podróż na ptasie safari w północnej ameryce.



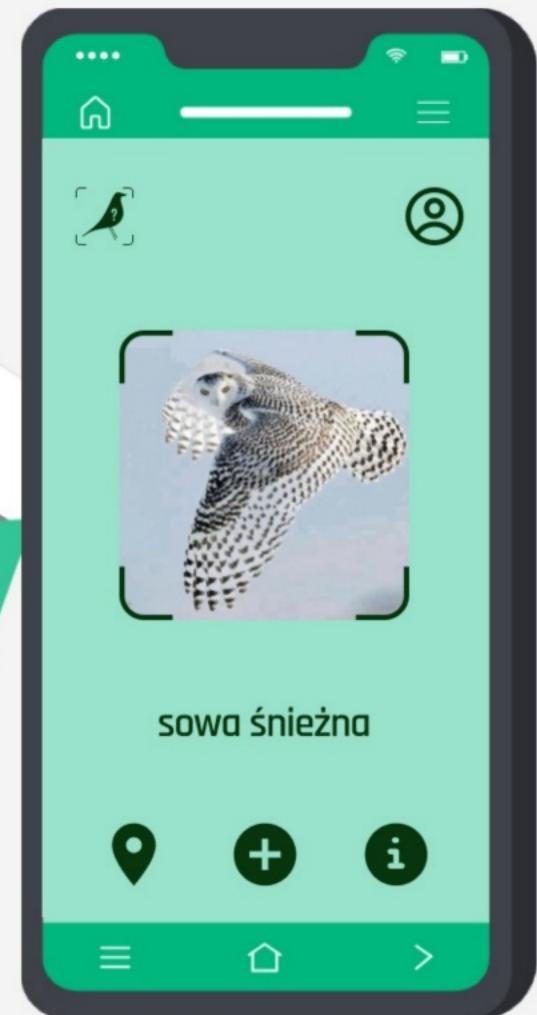
John podczas podróży zaobserwował wiele gatunków ptaków.
Aplikacja działała doskonale.



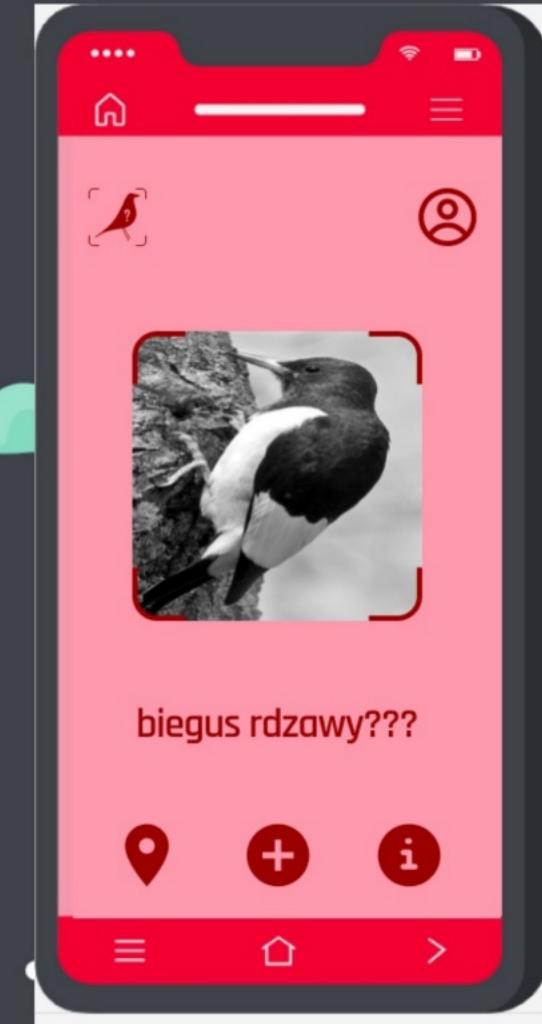
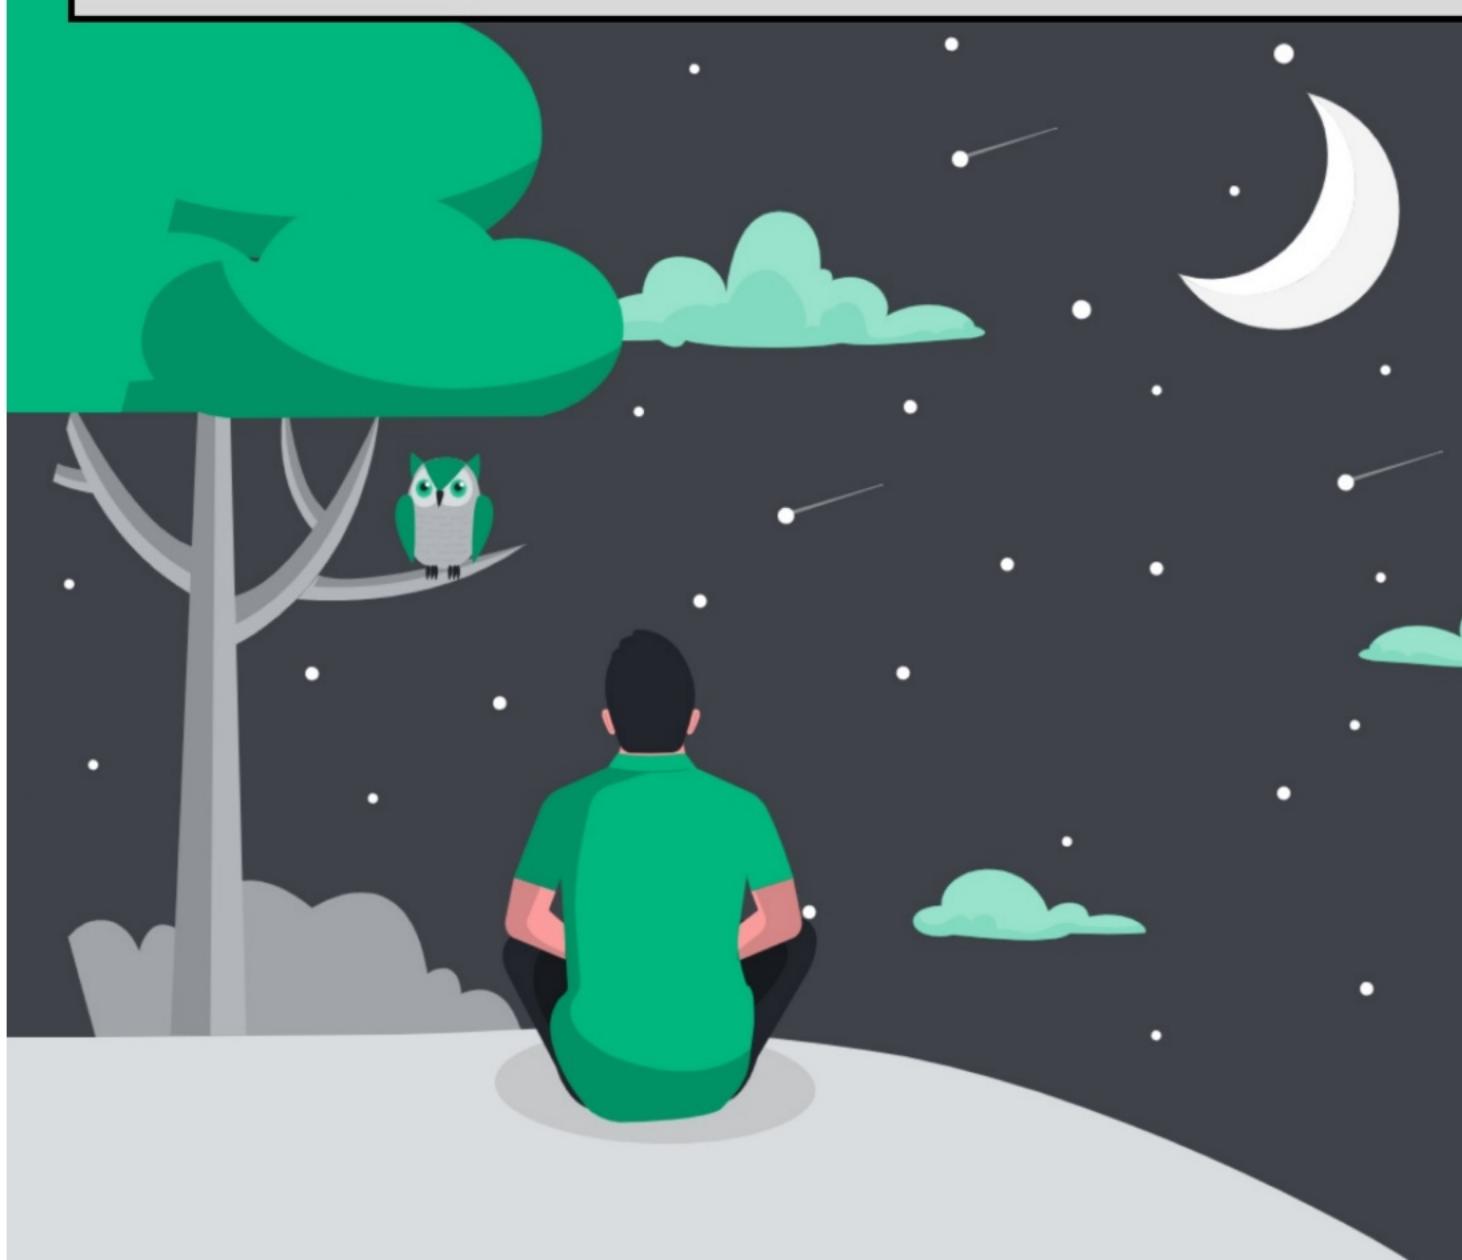
Kolejne napotkane okazy aplikacja rozpoznawała bez błędu.



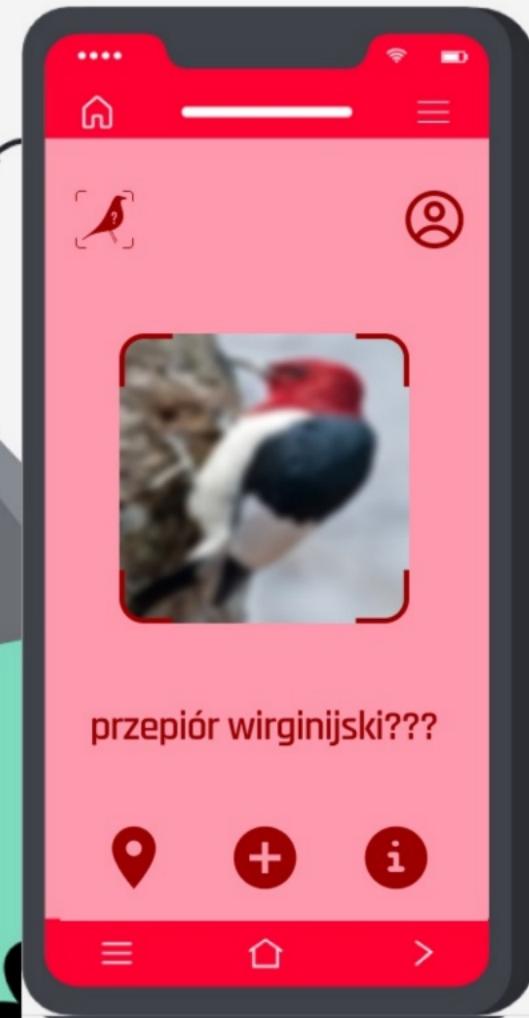
Aplikacja sprawdzała się też w warunkach,
gdy fotografowany był ptak w locie.



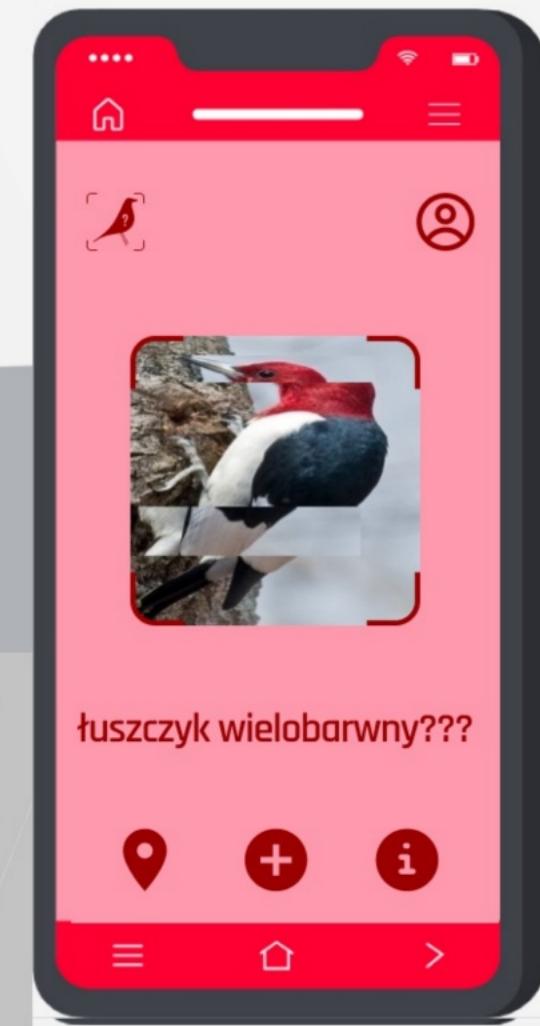
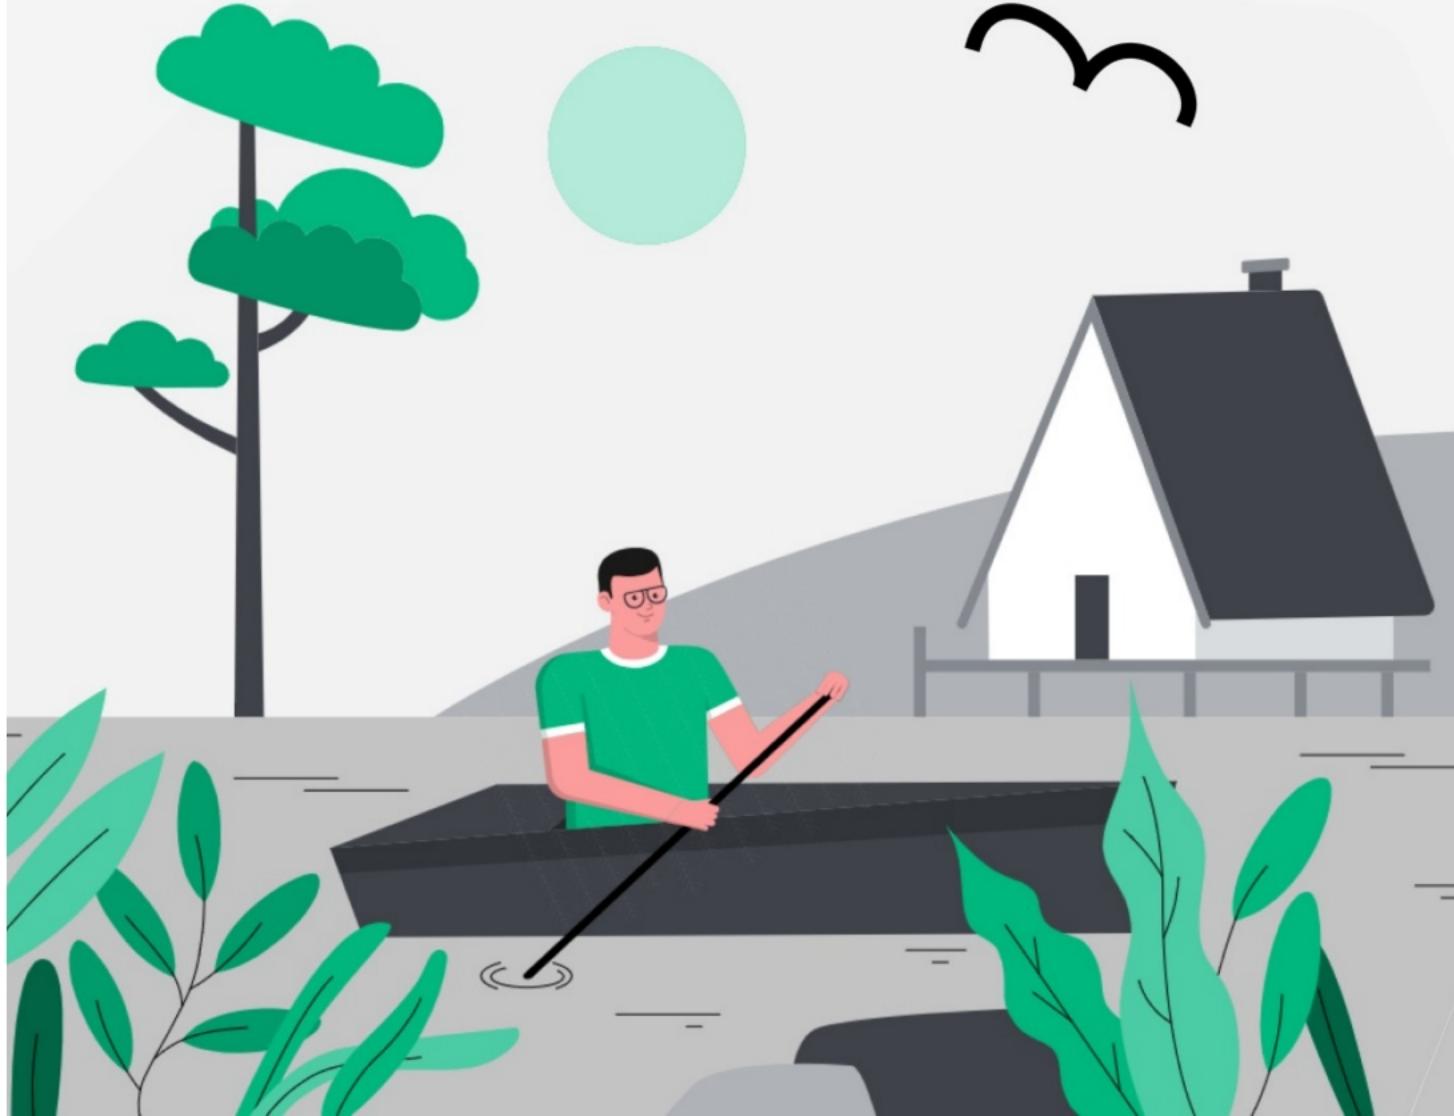
Jednak Johna spotkało kilka sytuacji, w których aplikacja nie działała tak jak powinna.
Problematyczne okazały się zdjęcia po zmroku, na których **nie było widać kolorów**.



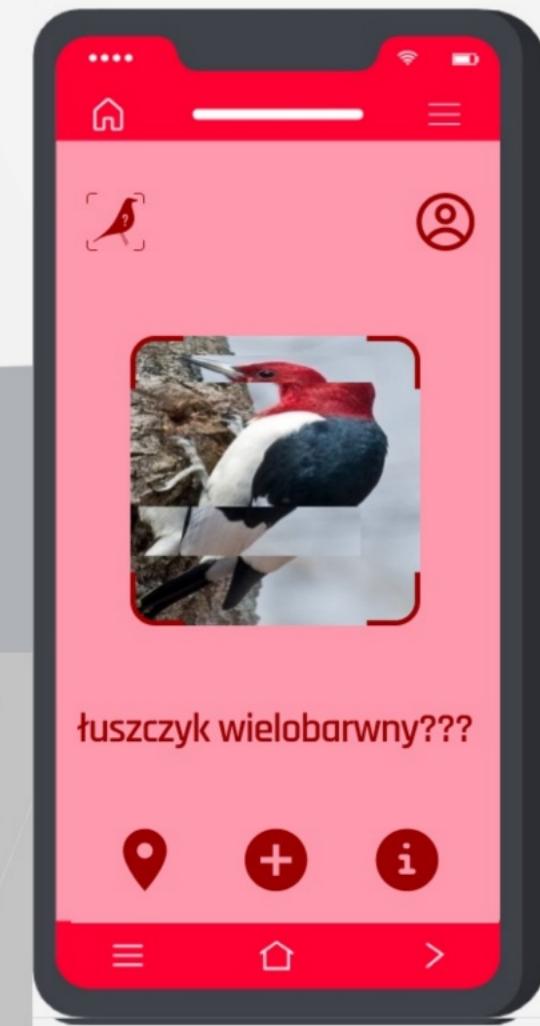
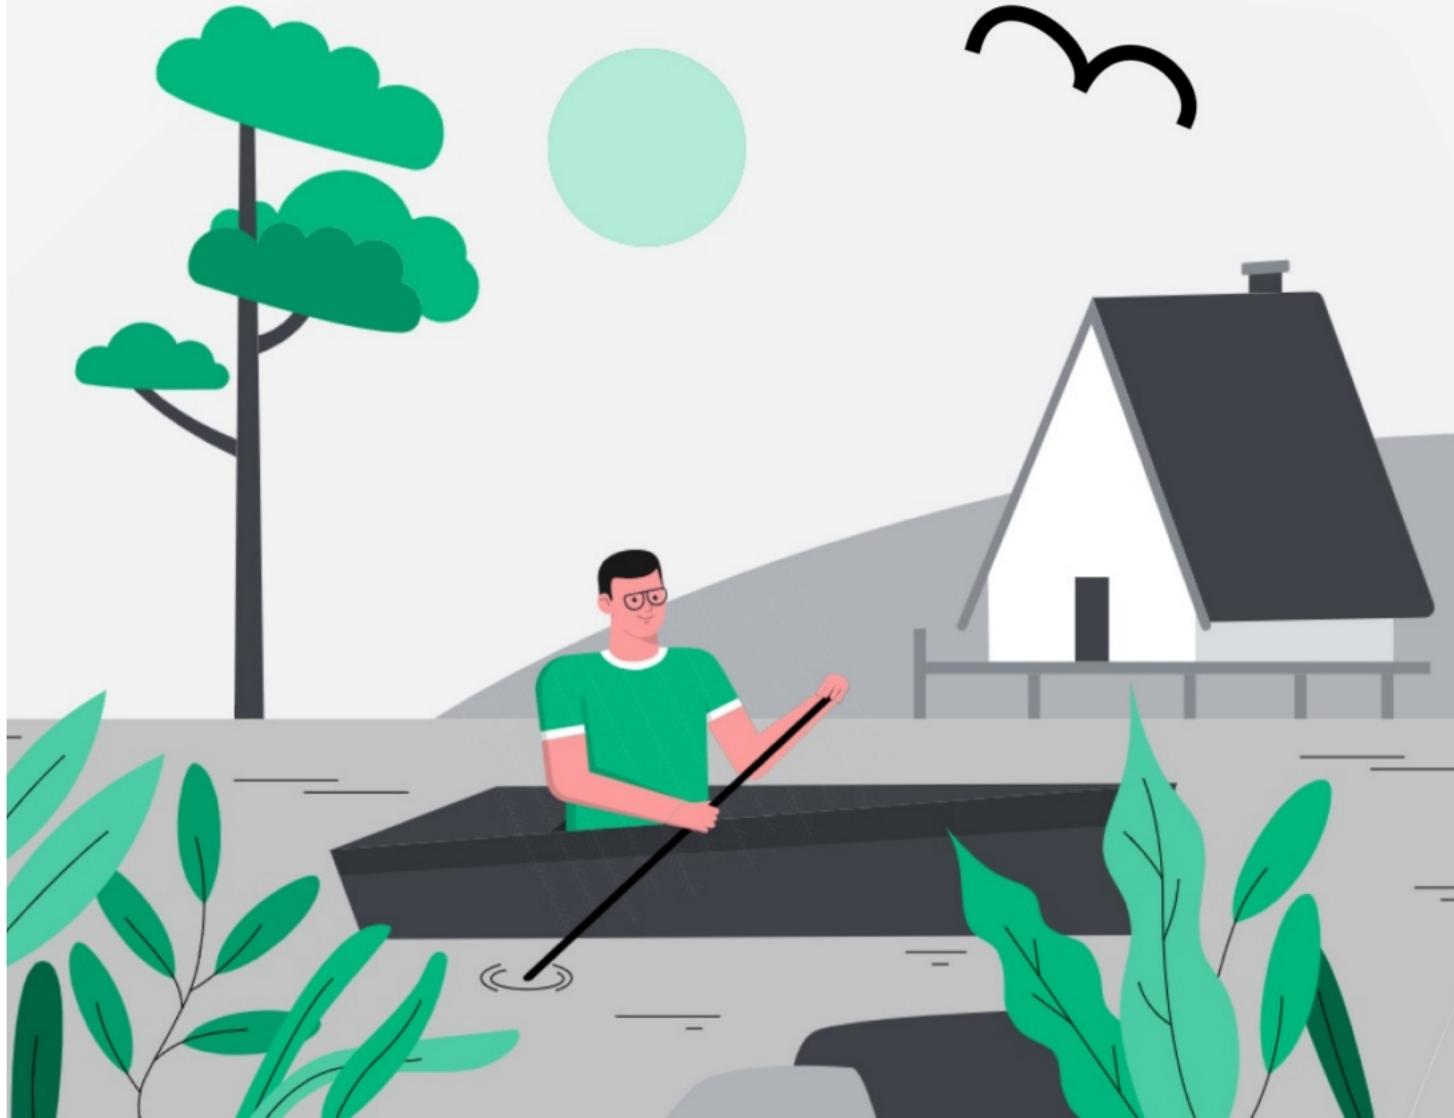
W kolejnej lokalizacji zdjęcia wyszły **rozmyte** i nie było szansy na powtórke.



Natomiast próbując zrobić zdjęcie w trudnych warunkach, karta pamięci zawiodła
i zdjęcie uległo **deformacji** przy zapisie.



Natomiast próbując zrobić zdjęcie w trudnych warunkach, karta pamięci zawiodła
i zdjęcie uległo **deformacji** przy zapisie.





skala szarości

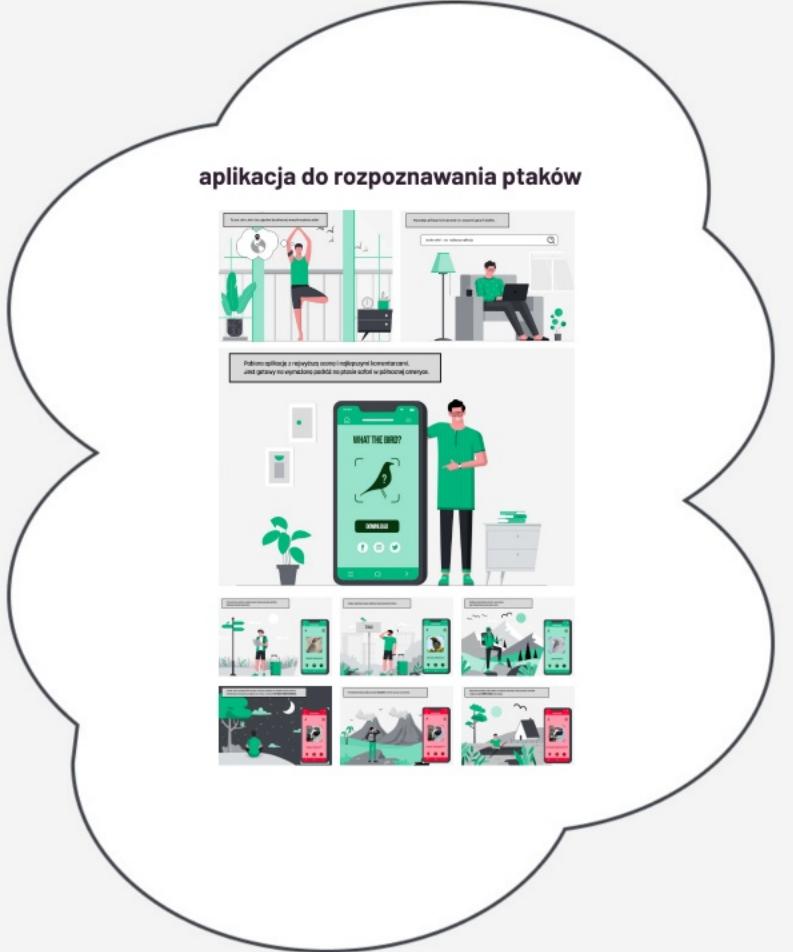


rozmycie



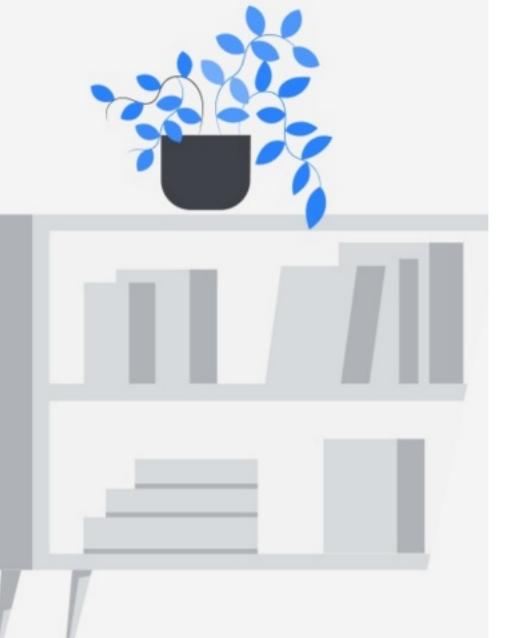
glitch

finalne parametry dokładności
wyniki modelu po przetrenowaniu na pow



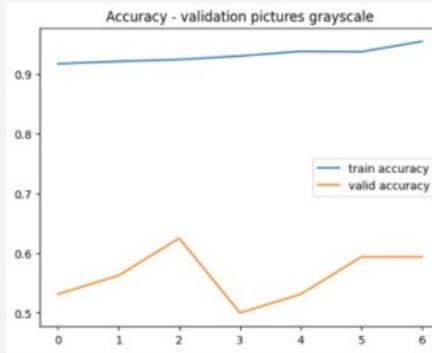
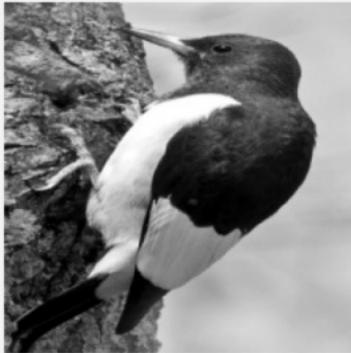
Aplikacja niepoprawnie klasyfikuje zdjęcia z defektami.
Przykładowe zdjęcia, które sprawiają problem to:
- brak kolorów / zdjęcie zrobione w trybie szarości,
- zdjęcie niewyraźne / rozmazane,
- zdjęcie zapisane z błędem np. karty pamięci.

Sprawdzenie, jak model radzi sobie z takimi zdjęciami.

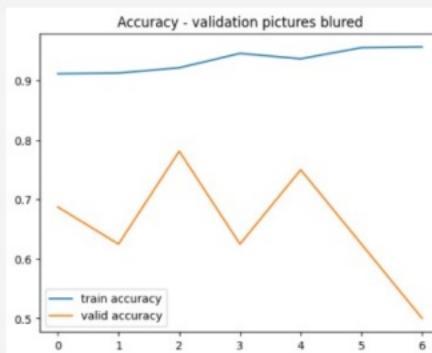
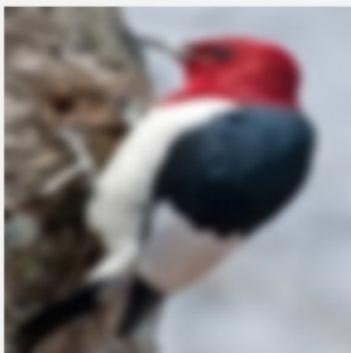


jak model poradzi sobie ze zdjęciami z wadami?

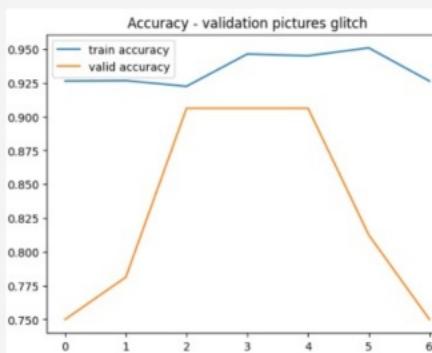
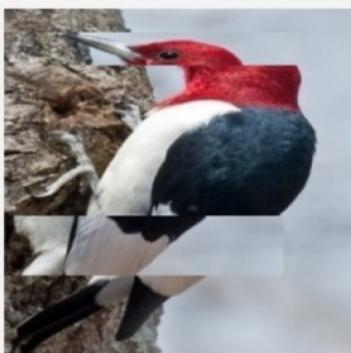
wyniki (dokładność) modelu na zbiorach obrazów walidacyjnych z defektami / zniekształceniami



skala szarości



rozmycie



glitch

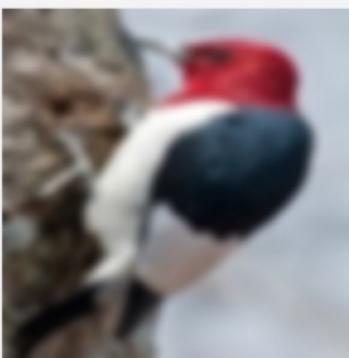
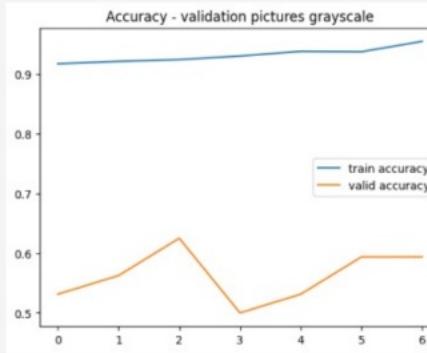


jak model poradzi sobie ze zdjęciami z wadami?

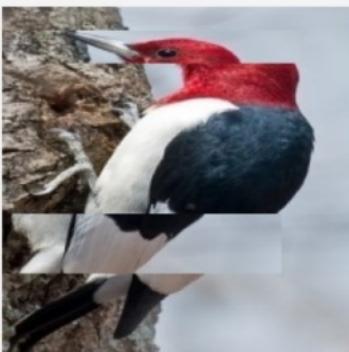
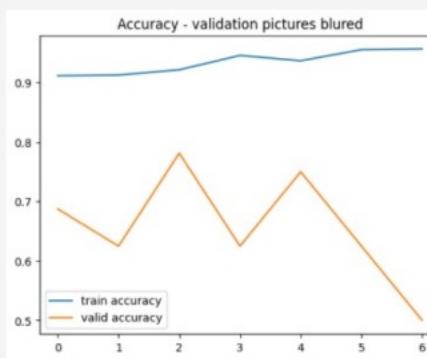
wyniki (dokładność) modelu na zbiorach obrazów walidacyjnych z defektami / zniekształceniami



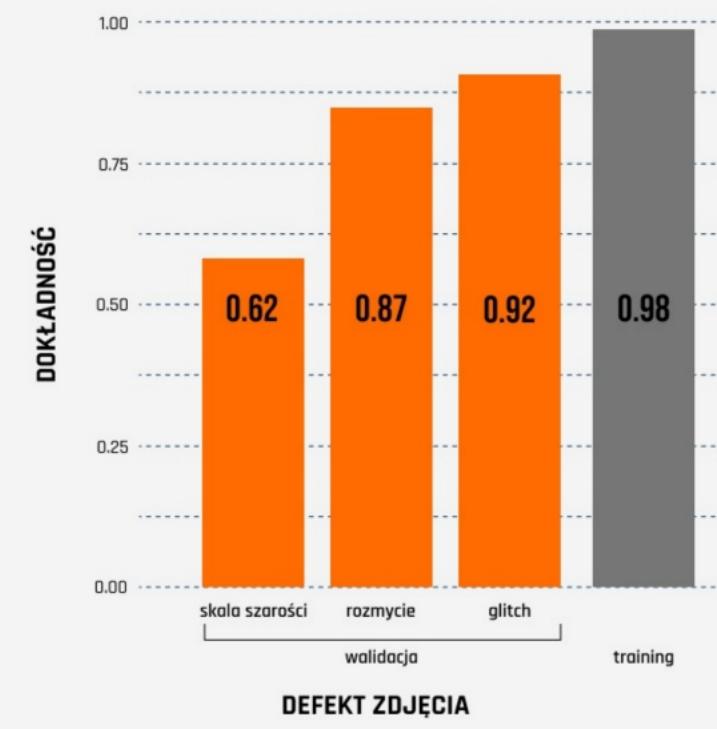
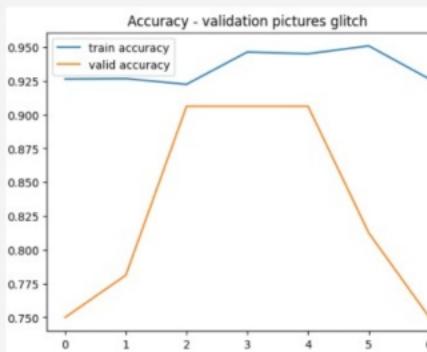
skala szarości



rozmycie



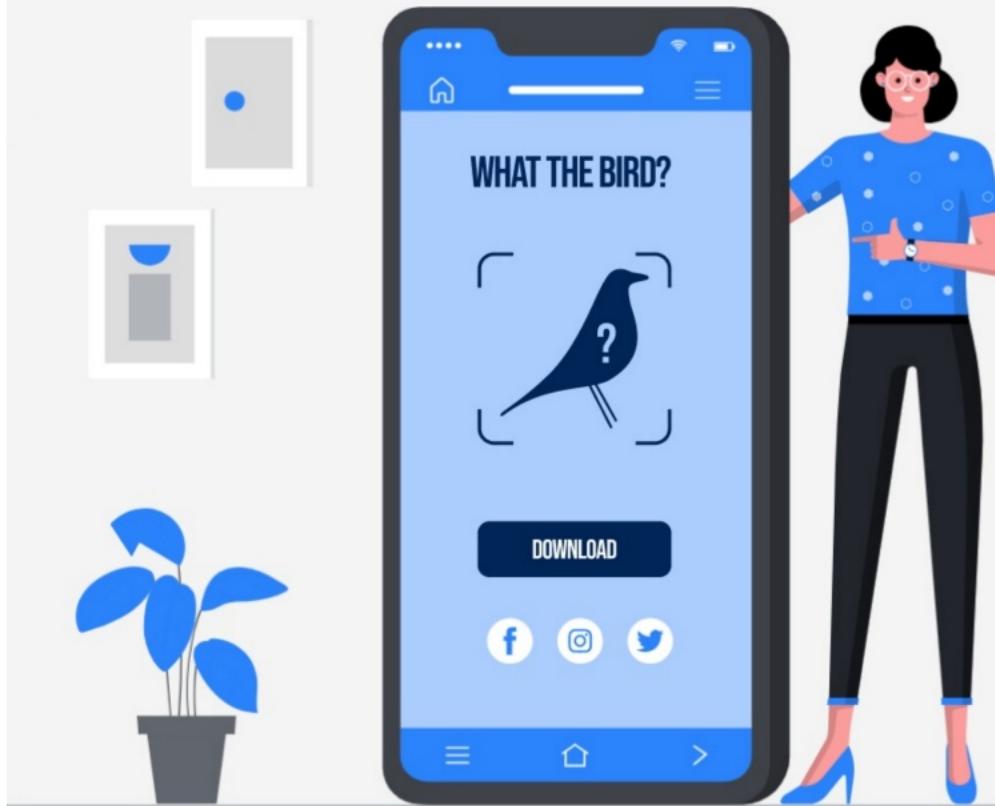
glitch



DEFEKTY ZDJĘCIA

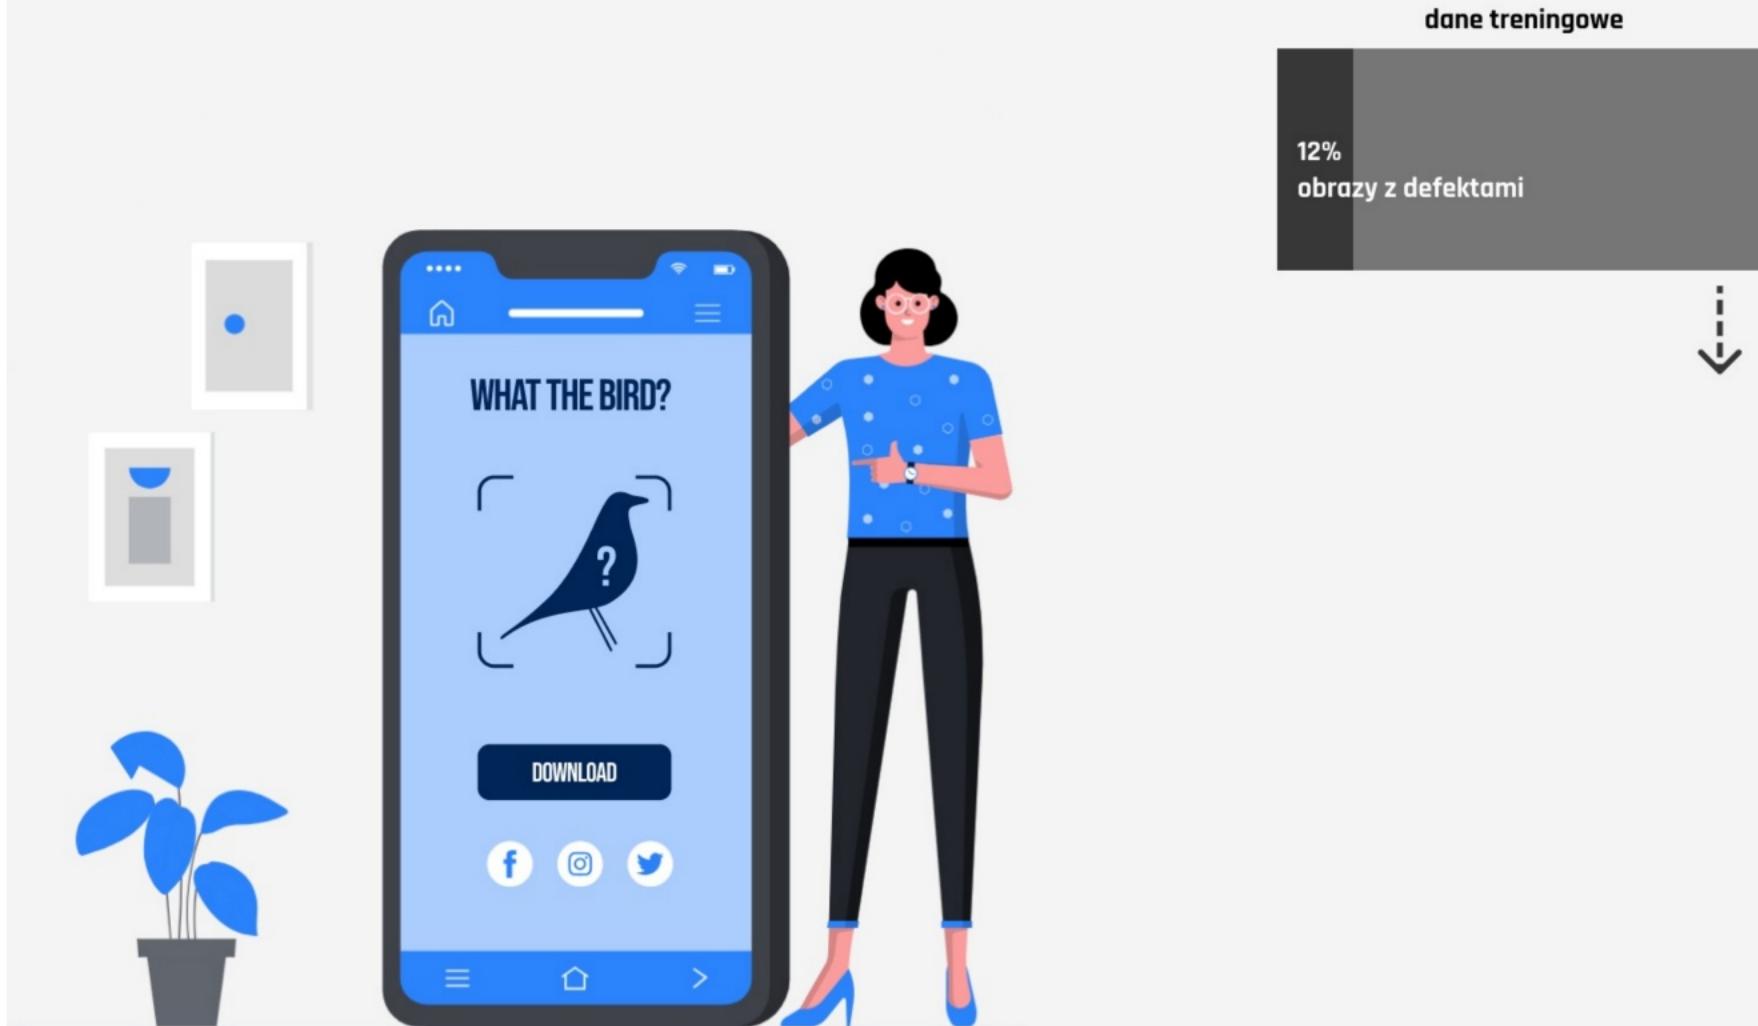
finalne parametry dokładności dla modelu

wyniki modelu po przetrenowaniu na powiększonym zestawie zdjęć treningowych o zdjęcia z defektami / zniekształceniami



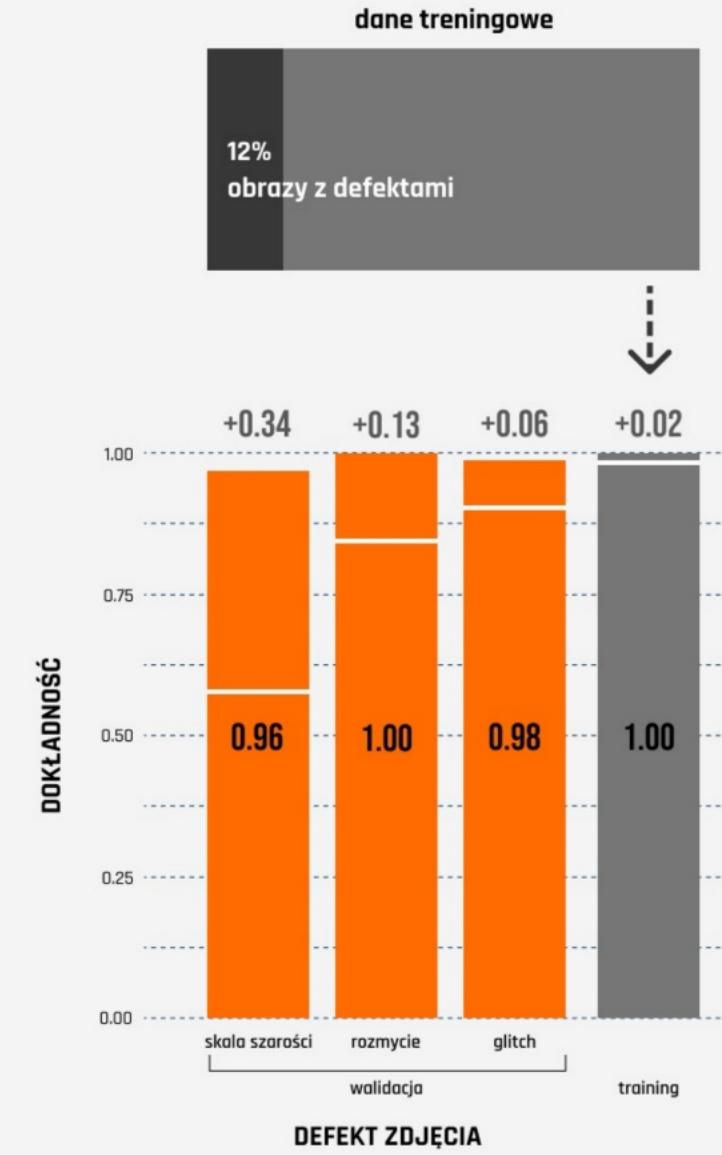
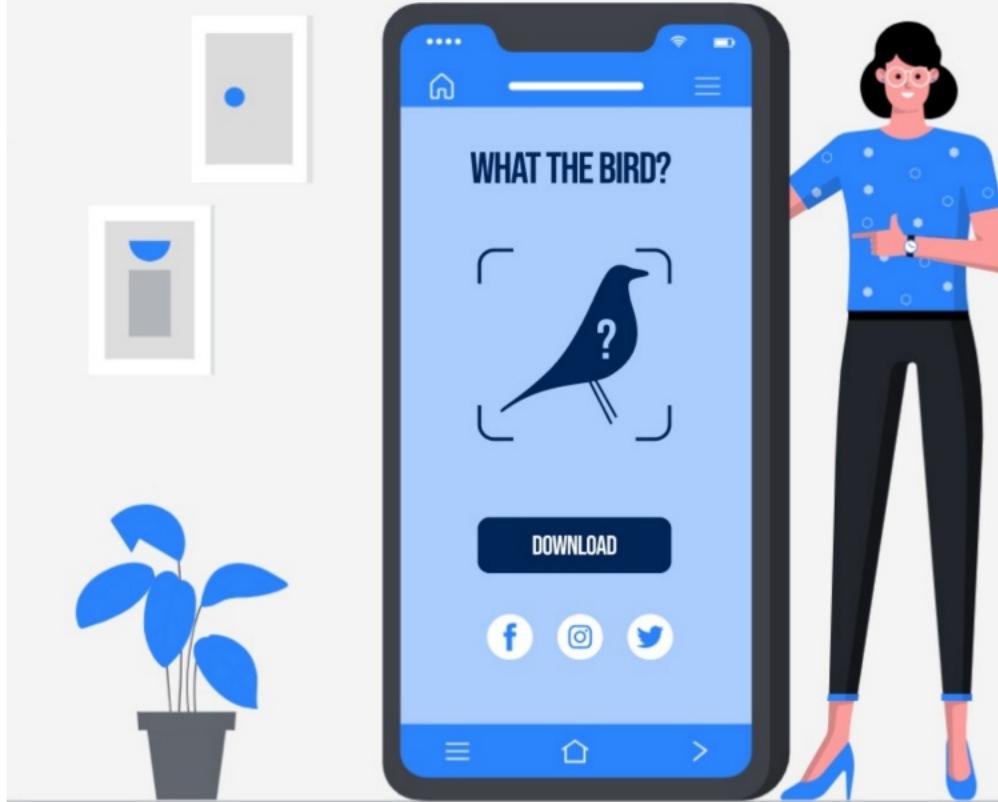
finalne parametry dokładności dla modelu

wyniki modelu po przetrenowaniu na powiększonym zestawie zdjęć treningowych o zdjęcia z defektami / zniekształceniami



finalne parametry dokładności dla modelu

wyniki modelu po przetrenowaniu na powiększonym zestawie zdjęć treningowych o zdjęcia z defektami / zniekształceniami



Jaki to PTAK?

Stworzenie modelu do rozpoznawania ptaków na terenie Ameryki Północnej

